



清华大学

综合论文训练

数据驱动的流域模型构建 与河道水质预警研究

系 别：未央书院

专 业：数理基础科学 + 环境工程

姓 名：何天怡

指导教师：曾思育 教授

二〇二五年六月

摘 要

流域水文水质模型是水污染防治规划与流域管理决策的重要技术手段。随着生态环境监测技术的快速发展与应用,数据驱动的流域水质模型逐步成为可能。针对传统机理模型在预测过程中需要大量资料和高计算成本的不足,本文以赤水河云南段流域为研究区域,融合遥感数据、气象数据、污染源排放数据,基于多源数据融合开发流域水质预测模型,并对关键河道断面开展水质预警研究,为流域水质监控和管理提供技术支撑。

本文以流域内清水铺断面和石坎断面水质为模拟对象,分别构建了基于人工神经网络(Artificial Neural Network, ANN)的时间预测预警模型集和基于时空图卷积网络(Spatial-Temporal Graph Convolutional Network, STGCN)的时空预测预警模型集,预测指标包括逐日平均流量(Q)、高锰酸盐指数(IMn)、氨氮($\text{NH}_4^+\text{-N}$)、总磷(TP)和总氮(TN)。经系统训练和评估,获得不同水质指标对应的最优超参数。结果显示,ANN模型和STGCN模型训练过程均收敛稳健,决定系数(R^2)分别达到0.75和0.90以上。两模型的均方根误差(RMSE)、平均绝对误差(MAE)、平均绝对百分比误差(MAPE)等指标也均在合理范围内。本文采用固定阈值法对关键水质指标进行超标时段预警,可支撑案例区水质管理。

对于清水铺断面,相较ANN模型,STGCN模型在关键水质指标的预测中有更优表现,RMSE、MAE、MAPE均有明显降低。特别是在 $\text{NH}_4^+\text{-N}$ 的预测中,STGCN模型的RMSE、MAE、MAPE在测试集上的表现分别提升了80.56%、96.07%、99.72%。考虑到流域内具备高频水质观测数据的断面数量有限,本文进一步探讨了STGCN模型的跨子流域迁移能力。将石坎断面所在子流域训练所得的STGCN模型迁移至清水铺断面所在子流域后,其预测性能依然稳定,表现接近原始模型。通过同时提取空间与时间信息,STGCN模型能更有效捕捉污染物空间扩散特征与时间动态变化,显著提升以耕地与林地为主的流域水质预测精度,具备在不同地理区域间的迁移可行性与泛化能力。

关键词: 多源数据融合; 流域水质预测; 机器学习; 人工神经网络(ANN)模型; 时空图卷积(STGCN)模型

Abstract

Watershed hydrology and water quality models are essential technical tools for water pollution prevention planning and watershed management decision-making. With the rapid development and application of ecological and environmental monitoring technologies, data-driven watershed water quality models have become increasingly feasible. To address the limitations of traditional mechanistic models—namely, their high demands for background information and computational resources—this study focuses on the Yunnan section of the Chishui River Basin. By integrating remote sensing data, meteorological data, and pollutant emission data, we develop a watershed water quality prediction model based on multi-source data fusion and conduct water quality early warning research for key river sections, providing technical support for watershed monitoring and management.

The study targets two monitoring sections—Qingshuipu and Shikan—and establishes two sets of early warning models: a time-series prediction model set based on the Artificial Neural Network (ANN) and a spatial-temporal prediction model set based on the Spatial-Temporal Graph Convolutional Network (STGCN). The predicted indicators include daily average discharge (Q), permanganate index (IMn), ammonia nitrogen (NH_4^+-N), total phosphorus (TP), and total nitrogen (TN). Through systematic training and evaluation, the optimal hyperparameters for different water quality indicators are obtained. Results show that both ANN and STGCN models exhibit robust convergence, with coefficients of determination (R^2) exceeding 0.75 and 0.90, respectively. Other evaluation metrics such as Root Mean Square Error (RMSE), Mean Absolute Error (MAE), and Mean Absolute Percentage Error (MAPE) also fall within acceptable ranges. Fixed-threshold-based early warning is applied to key water quality indicators, enabling effective management support in the case study region.

For the Qingshuipu section, the STGCN model outperforms the ANN model in predicting key water quality indicators, showing substantial reductions in RMSE, MAE, and MAPE. Specifically, in the prediction of NH_4^+-N , the STGCN model achieves improvements of 80.56%, 96.07%, and 99.72% over the ANN model in terms of RMSE, MAE, and MAPE, respectively, on the test set. Considering the limited availability of high-

frequency water quality data across monitoring sites in the basin, this study further investigates the transferability of the STGCN model across sub-basins. When the STGCN model trained on the Shikan sub-basin is transferred to the Qingshuipu sub-basin, the model maintains stable prediction performance, comparable to the original model. By capturing both spatial and temporal features, the STGCN model effectively characterizes pollutant diffusion patterns and temporal dynamics, significantly improving water quality prediction accuracy in a cropland- and forest-dominated basin. The model demonstrates promising potential for cross-regional transfer and generalization.

Keywords: Multi-source data fusion; Watershed water quality prediction; Machine learning; Artificial Neural Network (ANN) model; Spatio-temporal Graph Convolutional Network (STGCN) model

目 录

第 1 章 绪论	1
1.1 研究背景	1
1.2 国内外研究现状	2
1.2.1 流域水质预测模型的技术演变与方法体系	2
1.2.2 流域水质预测模型中的数据驱动方法演进	3
1.2.3 流域水质预测中的变量选取逻辑与多源数据融合进展	5
1.2.4 水质变化驱动因子的识别方法与研究进展	6
1.2.5 水质预警机制的研究进展	7
1.3 研究目的与意义	8
1.4 研究内容与技术路线	9
第 2 章 数据驱动的流域建模与水质预警方法	12
2.1 案例区概况与数据来源	12
2.2 数据预处理方法	15
2.3 变量筛选与重要性评估方法	18
2.3.1 相关性分析	18
2.3.2 多元线性回归分析	19
2.3.3 随机森林变量重要性评估	19
2.4 基于机器学习的水质预测方法	20
2.4.1 人工神经网络	20
2.4.2 时空图卷积网络	21
2.5 模型评估方法	22
2.6 预警机制与方法	23
2.7 本章小结	24
第 3 章 时空数据集构建	25
3.1 气象、污染排放、水文、水质数据预处理	25
3.2 遥感数据预处理	25
3.3 流域植被覆盖信息提取	27

3.4 关键气象站识别	30
3.5 本章小结	31
第 4 章 基于 ANN 的河流水质时间预测模型构建与应用	33
4.1 关键输入变量识别	33
4.2 河流水质时间预测模型构建	34
4.3 ANN 模型可解释性分析	40
4.4 ANN 模型用于河流水质预警	42
4.5 本章小结	43
第 5 章 基于 STGCN 的流域水质时空预测模型构建与应用	44
5.1 关键输入变量识别与优化	44
5.2 流域水质时空预测模型构建	46
5.3 STGCN 模型可解释性分析	47
5.4 STGCN 模型用于流域水质预警	58
5.5 STGCN 模型在不同子流域的迁移应用	59
5.6 STGCN 模型在缺乏水质观测数据的流域中的迁移应用	61
5.7 ANN 模型与 STGCN 模型的对比分析	71
5.8 本章小结	72
第 6 章 结论与建议	74
6.1 结论	74
6.2 建议	75
参考文献	76
附录 A 外文资料的书面翻译	82
致 谢	98
声 明	100

插图清单

图 1.1	研究技术路线图	11
图 2.1	赤水河（云南段）流域地理位置、河流水系示意图	12
图 2.2	ARIMA 模型插值流程图	16
图 2.3	时空图结构示意 ^[65]	21
图 2.4	STGCN 模型结构图 ^[65]	22
图 3.1	研究区域子流域示意	27
图 4.1	清水铺断面 ANN 模型预测结果	40
图 4.2	清水铺断面 ANN 模型预警结果	42
图 5.1	石坎断面 STGCN 模型预测预警结果	59
图 5.2	清水铺断面 STGCN 模型预测预警结果	61

附表清单

表 1.1	流域水质预测模型的技术演变与方法体系	3
表 2.1	赤水河流域地表水环境监测断面信息	14
表 2.2	研究所用主要数据清单	14
表 2.3	地表水水质 II 类标准限值	24
表 3.1	波段的波长范围与典型用途	26
表 3.2	子流域网格划分	28
表 3.3	清水铺断面关键气象站识别结果	31
表 3.4	石坎断面关键气象站识别结果	31
表 4.1	未经选择的输入变量	33
表 4.2	输入变量选择结果	34
表 4.3	清水铺断面目标变量的 ANN 模型结构组合	36
表 4.4	清水铺断面 ANN 模型最优超参数与评价指标	38
表 4.5	各目标变量对应的主要影响因子及其特征重要性排序	41
表 5.1	未经选择的 STGCN 模型输入变量	44
表 5.2	STGCN 模型输入变量选择结果	45
表 5.3	污水处理厂变量与石坎断面目标变量的最佳滞后天数	46
表 5.4	石坎断面目标变量的 STGCN 模型结构组合	48
表 5.5	石坎断面 STGCN 模型最优超参数与评价指标	56
表 5.6	各目标变量对应的主要影响因子及其特征重要性排序	56
表 5.7	清水铺断面 STGCN 模型最优超参数与评价指标	60
表 5.8	STGCN 模型输入变量选择结果	62
表 5.9	石坎断面目标变量的 STGCN 模型结构组合	63
表 5.10	石坎断面 STGCN 模型最优超参数与评价指标	71
表 5.11	ANN 模型与 STGCN 模型对比分析	72

第 1 章 绪论

1.1 研究背景

近年来，我国水环境治理工作取得了显著成效。据《2023 年中国生态环境状况公报》^[1]，2016~2023 年，全国地表水中 I~III 类水质断面比例由 67.8% 上升至 89.4%，劣 V 类水体比例由 8.6% 下降至 0.7%。这表明国家在干流和国控断面的治理上取得了明显成果。然而，区域性污染问题依然严峻，尤其体现在支流、次级支流和中小河流的水质未有实质性改善。《“十四五”重点流域水环境综合治理规划》^[2]指出，部分区域仍存在劣 V 类断面，流域精细化治理能力亟待提升，迫切需要更具针对性的水质预测与预警技术支撑。

从政策层面来看，国家对水质预测预警在流域环境管理中的作用日益重视。自 2016 年以来，生态环境部陆续发布《生态环境大数据建设总体方案》《生态环境智慧监测创新应用试点工作方案》等政策文件，2020 年国务院印发的《关于构建现代环境治理体系的指导意见》亦明确提出，将水质预警纳入环境治理的重要手段。上述文件均强调应依托大数据分析 with 智能感知技术，提升生态环境监测预警能力。相关政策的持续推进为水质风险识别与响应机制的构建提供了制度保障，也进一步凸显了水质预警技术在现代流域治理体系中的战略地位。

与此同时，水质预测预警技术的实现面临多重挑战。首先，流域系统本身具有高度的空间异质性和动态复杂性。水质变化受气象、水文、污染源、人类活动等多因素交织影响，传统单一河段模型难以适应流域尺度的综合治理需求。构建具有多维输入和空间传递机制的流域模型已成为趋势。其次，多源数据的协同融合仍存在难点。不同数据源（如遥感影像、地表监测、气象观测、污染排放）在空间分辨率、时间尺度与获取频率上存在显著差异，要求建模过程具备动态参数调节能力与高精度数据处理方案。此外，如何权衡模型结构的复杂性与通用性、确定合理的输入变量集并控制维度冗余，也是当前建模实践中的核心问题。

当前阶段，多源数据获取能力不断提升，为流域建模与风险识别提供了可能基础。例如，2023 年我国地表水国控断面已达 3632 个，遥感技术支持 10m 分辨率土地利用提取，气象自动观测站超过 7.6 万个，社会经济数据通过各级统计系统可实现长期追踪。这些数据构建了支持高分辨率建模的坚实平台，为挖掘水质风险的时空驱动因子提供了条件。

综上所述，当前流域水质管理一方面面临区域性污染问题的治理压力，急需科学、精准的预测与预警工具；另一方面，尽管多源数据获取能力不断增强，为模型构建提供了丰富的信息基础，但数据异质性高、输入变量复杂、模型结构设计难度大等技术挑战依然存在。面对水质风险的时空复杂性与区域多样性，亟需构建兼顾精度与适应性的流域水质预测与预警模型，以支撑流域精细化管理与风险响应机制的构建。

1.2 国内外研究现状

1.2.1 流域水质预测模型的技术演变与方法体系

水质预测研究可追溯至 20 世纪初。1925 年，H. Streeter 与 E. Phelps 在研究俄亥俄河污染问题时首次提出了基于物理化学过程的经验方程模型——BOD-DO 模型，将水质变化与污染物的自净过程联系起来，为后续水质建模奠定了数学基础^[3]。该模型通过描述溶解氧（DO）与生化需氧量（BOD）的动态演变，为水质预测构建了早期的理论框架。

随着水环境问题的日益严峻，20 世纪 50 年代至 70 年代，水质模型从单一河段扩展至多河段、多组分的复杂系统，逐步发展出基于物质守恒原理的多维模型。这类模型通过刻画污染物的迁移、转化与沉降过程，增强了对复杂流域水质过程的描述能力^[4]。

进入 20 世纪 70 年代至 90 年代，机理模型进一步成熟，主要形成了水动力学模型、水质过程模型与生态模型三种主要类型。水动力学模型（如 SWAT、HEC-RAS、MIKE）着重模拟水体的流速、流向与水位等动态行为，适用于河流、湖泊与水库等多类型水体的流动建模^[5]。水质过程模型（如 QUAL2K、WASP）则强调污染物的反应机制及其时空演化特征，可用于定量评估污染负荷与治理成效^[6]。生态模型（如 CAEDYM、AQUATOX）进一步将生物群落的演替过程纳入建模框架中，适用于生态系统健康评估等综合性分析^[7]。

自 20 世纪 90 年代起，随着计算能力的提升和数据获取手段的丰富，统计模型逐渐成为水质预测研究的重要补充。时间序列分析方法（如 ARIMA）及多元线性回归模型被广泛用于短期预测任务，这些模型具有计算效率高、实现简便的优点，尤其适用于常规监测数据的快速分析^[8]。然而，由于其本质为数据驱动，缺乏对污染过程机制的深入解析，往往在处理高维、非线性系统时表现出较大局限性。

与此同时，传统机理模型的局限性也日益显现。尽管其解释性强、理论基础扎

实，但对初始条件和参数设定高度敏感，且在复杂流域场景下存在较高的不确定性，制约了其广泛适用性^[9]。相比之下，统计模型虽然效率较高，却难以有效捕捉污染物行为的非线性与时空异质性特征^[10]。

在数据科学不断发展的背景下，混合建模方法逐渐兴起，成为水质预测研究的新趋势。这一方法融合了机理模型的结构优势与数据驱动模型的灵活适应性，在保障理论解释力的同时提高了模型的预测能力与泛化性能。例如，Bui 等人^[11]提出了一种结合多种机器学习算法的混合模型，用以提升水质指数的预测精度；Rajacee 等人^[12]系统综述了基于人工智能的单一与混合建模方法，并指出混合模型在提升河流水质预测表现方面具有显著优势。Lu 与 Ma^[13]进一步发展了融合决策树与分解算法的混合预测模型，尤其在短期预测场景中表现出较强的时间动态适应能力。这些研究表明，混合模型通过整合不同建模策略与方法论路径，有效提升了水质预测的准确性与实用性，展示了广阔的应用前景。

表 1.1 流域水质预测模型的技术演变与方法体系

类别	方法介绍	常见模型
机理模型	(1) 水动力模型：主要描述水体的流动特性，如流速、流向、水位等，包括一维、二维、三维模型。	常见如 SWAT、HEC-RAS、MIKE 等
	(2) 水质过程模型：主要描述水体中污染物的迁移、转化和沉积等过程。	常见如 QUAL2K、WASP、EFDC 等
	(3) 生态模型：主要描述水体中生物群落的结构和功能，如藻类生长、有机物分解等。	常见如 CAEDYM、AQUATOX、PCLake 等
非机理模型	(1) 数理统计模型：通过统计方法（如回归分析、时间序列分析）建立水质指标与影响因素之间的关系。	常见如线性回归、多元回归和 ARIMA 等
	(2) 人工智能模型：利用计算机科学和数学方法对大量数据进行学习，以自动发现输入与输出之间的关系，包括深度学习和机器学习等。	常见如人工神经网络（ANN）、支持向量机（SVM）、随机森林（RF）等

1.2.2 流域水质预测模型中的数据驱动方法演进

随着传感器技术、数据存储能力及计算资源的持续发展，20 世纪末以来，数据驱动方法逐渐被引入流域水质预测研究。早期应用主要以人工神经网络（Artificial Neural Network, ANN）为代表，通过对历史监测数据的学习来识别水质变化中的非线性规律。研究表明，ANN 在预测总磷（TP）、化学需氧量（COD）和溶解氧

(DO) 等关键指标方面表现出良好性能, 为水质预测方法体系的智能化转型奠定了基础^[14]。

进入 21 世纪, 机器学习技术逐渐走向成熟, 多种方法被广泛应用于水质建模中。支持向量机 (Support Vector Machine, SVM) 在处理高维数据和分类任务中展现出优越性能, 例如被用于水质等级划分, 显著提升了分类精度^[15]。随机森林 (Random Forest, RF) 模型则凭借其非线性关系的良好建模能力, 尤其在多变量分析中表现出色, 通过特征重要性评估机制帮助研究者识别主导水质变化的关键因子, 从而增强模型的可解释性与适应性^[16]。

在应用层面, 机器学习模型具备多重优势。其对复杂非线性关系的拟合能力远超传统统计方法。例如, Heddam^[17] 利用多层感知器神经网络 (MLP) 建模蓝藻色素浓度的非线性演变过程。Barzegar 等^[18] 将集成学习方法与波形变换技术相结合, 提高了时序预测的稳定性与精度。Zhang 等^[19] 基于改进的模糊物质-元素扩展模型, 实现了对极端污染事件的跟踪与拟合。

随着深度学习的发展, 其在水质预测中的应用成为研究前沿。长短期记忆网络 (Long Short-Term Memory, LSTM) 在处理溶解氧与总氮等动态指标时表现优异^[20]。CNN-LSTM 模型融合了卷积神经网络与 LSTM 的优势, 能够同时提取空间与时间特征, 适用于土地利用与水质演化的耦合建模^[21]。近期研究还尝试将 Transformer 架构引入流域建模任务, 用于多源数据学习与变量复杂关系的解析^[22]。

混合建模方法日益受到重视。通过将物理建模的机理优势与数据驱动模型的灵活性结合, 混合模型不仅提升了预测精度, 还增强了对环境系统机制的解释力。例如, Chen 等^[23] 提出将水动力学模型与 LightGBM 相融合的预测框架, 在保证模型精度的同时显著提高了效率与稳定性。Tiyasha 等的综述指出, 将水力模型与深度学习模型相结合, 是未来河流水质建模的重要发展方向^[24]。

尽管数据驱动模型在水质预测中取得显著进展, 但仍面临若干挑战。首先, 模型对高质量数据依赖性强, 而常用的日或月尺度监测数据难以刻画水质的快速变化。高频数据虽具时效性, 但易受缺测与噪声干扰, 需依赖先进的缺失值插补与异常清洗技术^[25]。其次, 特征选择与降维仍是提高效率与可解释性的关键, Che 等人利用随机森林识别出东江流域水质的关键驱动因子, 为建模提供了优化路径^[26]。此外, 当前多数模型泛化能力有限, 难以适应不同地理条件或极端事件, 构建具备迁移能力的混合模型是提升模型适应性的关键方向^[24]。最后, 尽管 CNN 与 LSTM 理论上具备优势, 但在实际流域监测中的应用仍较有限, 未来仍需加强对其在复杂动态环境下的实证验证。

综上所述，数据驱动模型凭借强大建模能力和灵活适应性，在流域水质预测中展现出广阔前景。未来研究应进一步聚焦高频数据整合、特征选择优化、结构泛化能力与混合模型部署的可行性，以推动智能水环境管理体系建设。

1.2.3 流域水质预测中的变量选取逻辑与多源数据融合进展

在水质预测建模中，输入变量的选择不仅直接决定模型的性能和泛化能力，也是理解水质变化驱动机制的关键环节^[27]。合理的变量选取策略能够有效降低建模复杂性，提升预测精度，并增强模型的解释性与实用性。近年来，随着流域水质研究的深入，变量选择方法逐步从依赖机理模型的结构设定，转向融合经验知识与数据驱动方法的综合分析路径。

物理机理模型在输入变量选择方面提供了重要理论基础。以 SWAT（Soil and Water Assessment Tool）为代表的分布式水文模型，已被广泛用于流域尺度的水文过程模拟、非点源污染评估及水质动态建模。其模块化设计涵盖气象、水文、土壤、地形、土地利用等多个要素，为输入变量的科学筛选提供了逻辑支撑^[28-29]。例如，其水文与气象模块通常将降水、气温、风速和太阳辐射作为核心变量；土壤侵蚀与沉积模块依据 MUSLE 公式，强调坡度、土壤类型与地表覆盖率的重要性；农业管理模块聚焦施肥、作物种类与灌溉条件对污染物输出的影响^[30]；而水质模块则涉及溶解氧（DO）、总磷（TP）与化学需氧量（COD）等指标的时空输移过程^[31]。

在数据驱动模型快速发展的背景下，变量选择方式也呈现出从机理推导向数据挖掘转变的趋势。大量研究通过变量重要性排序、相关性分析与特征降维等方法，从多源数据中识别出与水质变化密切相关的关键变量。以水质监测数据为例，Abba 等人^[32] 在建立 DO 预测模型时，发现 pH、温度和 COD 对预测性能影响显著，表明理化指标间的交互关系在建模中不容忽视。气象与水文变量的引入显著提升了模型对水质波动的动态响应能力。Che 等人^[33] 利用随机森林模型揭示了极端降雨与径流流速对总磷浓度变化的显著驱动效应，而 Ficklin 等人^[34] 则进一步证明了气候变化情景下，降雨格局变化对流域水质结构的深远影响。

与此同时，土地利用、农业活动与社会经济变量在解释非点源污染负荷变化方面日益受到重视。Gazzaz 等人^[35] 在研究土地利用类型对水质的影响时发现，城市化水平和农田比例与总磷、总氮浓度高度相关。Zou 等人^[9] 则指出，施肥强度与农药使用量等农业管理变量对水质变化具有显著驱动作用。将这些社会经济变量纳入水质预测模型，不仅有助于揭示人类活动对流域生态过程的影响，也为综合管理策略的制定提供数据支持。

综上,流域水质预测中的变量选择正逐步从“单一来源、经验筛选”向“多源融合、数据挖掘”转变。未来的研究应进一步探索高频监测数据、遥感指标、实时气象数据与社会经济变量的协同整合机制,并开发适应异构数据结构的建模框架,以全面提升预测模型的精准性、稳定性与应用价值。

1.2.4 水质变化驱动因子的识别方法与研究进展

河流水质受气象因素、水文过程、土地利用、农业施肥强度和其他人为活动的共同作用,其变化机制高度复杂。为了提高水质模型的预测精度与可解释性,准确识别对水质具有主导影响的变量已成为当前建模与管理研究的核心任务。一方面,合理的驱动因子筛选有助于降低模型的输入维度,减少冗余信息,提高计算效率与泛化能力;另一方面,识别出的关键因子也为污染治理、资源配置及流域生态管理提供了明确的干预目标和科学依据。

在众多变量识别技术中,冗余分析(Redundancy Analysis, RDA)、主成分分析(Principal Component Analysis, PCA)和多元回归分析(Multiple Regression Analysis, MRA)是当前流域水质研究中应用广泛的多元统计方法。Liu 等人^[36]在农业流域的氮磷负荷分析中应用 RDA,发现耕地比例和施肥强度显著影响总氮(TN)和总磷(TP)浓度。Barzegar 等人^[37]通过 PCA 提取了气象与农业活动对水质的主要影响模式,强调了其在降维与模式识别中的作用。Zhang 等人^[38]则利用 MRA 构建溶解氧(DO)与土地利用、降雨强度及污染排放之间的定量关系,指出农业活动的贡献最为显著。

在此基础上,研究者开始关注变量选择对模型性能的具体影响,逐步引入面向特征选择的模型嵌入方法。其中,相关性分析(如皮尔逊相关系数)被广泛应用于变量初筛阶段,用于剔除与目标变量无显著相关性的输入项,作为后续建模的预处理步骤。Zhang 等人^[39]提出结合熵权法与皮尔逊系数的特征选择策略,在水质预测任务中取得了良好的变量筛选效果。

更为精细化的变量筛选方法是特征递归消除(Recursive Feature Elimination, RFE)。该方法通过构建初始模型并递次剔除贡献度最低的特征,反复训练与评估模型性能,最终确定对预测最具贡献的一组变量。Zheng 等人^[40]在城市河流的水质反演研究中将 RFE 与 Relief 排序相结合,显著提高了多光谱数据驱动模型的解释性与鲁棒性。相比于纯相关分析方法,RFE 具备更强的模型嵌入能力,能够识别变量与目标变量之间复杂的非线性作用关系。

值得注意的是,不同变量选择方法的适用场景各异。例如,RDA 和 PCA 更适

合探索变量之间的整体模式和共变结构，而 MRA 强调线性回归关系的定量建模；相关性分析适合用于初步过滤，RFE 则更适用于建立高精度预测模型时的特征选择。Zhang 等人^[38]在污染敏感流域研究中，结合 RDA、PCA 和 MRA 等方法系统分析了土地利用变化和降雨因子对水质的联合影响，验证了多方法融合在驱动因子识别中的价值。

未来研究可进一步探索多种方法的耦合机制，在提升变量识别效率的同时增强模型的可推广性与管理决策的支持能力。特别是在高频遥感、气象、实时监测等多源数据不断增加的背景下，如何将特征选择方法有效整合进深度学习和图神经网络等模型结构中，是推动水质预测模型发展和提升管理针对性的关键方向。

1.2.5 水质预警机制的研究进展

水质预警系统（Early Warning System, EWS）最初用于应对突发性污染事件，其早期应用可追溯至 1977 年美国俄亥俄河的四氯化碳泄漏事件^[41]以及 1986 年莱茵河化工事故^[42]，这些案例推动了水环境应急响应系统的发展。随着多灾种风险管理理论的发展，联合国减少灾害风险办公室（UNDRR）于 2023 年提出了 EWS 的系统性框架，强调灾害风险知识、监测与预测、信息传播及应急响应四大核心组成部分^[43]。这一理论为现代水质预警系统的构建提供了多维度指导。

在具体实践中，预警系统需根据流域特性进行功能模块的调整。然而，在跨流域或多源污染背景下，系统的响应效率与适应性仍面临挑战，尤其是在信息传递链条和实时决策能力方面。为提升系统性能，研究主要围绕监测指标的优化、监测网络的布局与警报触发机制展开。

监测指标的科学选取是提升系统灵敏度和准确性的关键因素。自 20 世纪 90 年代起，预警系统逐步引入生物指标作为毒性变化的先行信号。1994 年，Balk 等人^[44]最早在工业废水与地表水监测中采用生物学响应指标，开启了生物预警技术的应用路径。21 世纪初，Tryland 等人^[45]设计了半自动预警系统，显著缩短了粪便污染监测的响应时间。随后，蓝藻荧光在线监测方法的应用进一步拓展了指标体系，为水库与饮用水源地提供了更具前瞻性的风险管理工具^[46]。

与此同时，站点布局的优化直接影响预警系统的时空覆盖能力与响应效率。美国国家环境保护局（USEPA）^[47]提出，合理的传感器部署和监测站点分布是系统高效运行的基础。研究者逐步引入水动力模型对布局方案进行优化，提升了站点代表性与检测时效。Quansah 等人^[48]指出，结合水文动力模拟进行布局决策，可显著提升系统在复杂地形和多污染源环境中的实用性。Hofmann 与 Schüttrumpf^[49]、

Starzec 等人^[50]和 Papadimitriou 等人^[51]等后续实证研究进一步验证了基于水动力分析的站点优化策略在洪水及污染事件预警中的广泛适用性。

警报触发机制是预警系统运行的核心，其设计逻辑决定了污染事件识别的时效性与精准性。当前，固定阈值法仍为最常见的触发手段，但其对不同流域特征的适应能力有限，难以应对动态污染场景。为解决该问题，研究逐步引入动态阈值与波动分析方法，通过整合水质本底值与多指标联合异常检测，提升系统在多种污染类型下的适应性。例如，Xia 等人^[52]提出了基于多参数组合的动态预警方法，结合水源本底与事件特征生成阈值区间，提升了判断准确性。Bartlett 与 Dedekorkut-Howes^[53]进一步结合气候变化背景，提出区域适应性阈值设计。Shi 等人^[25]通过引入小波变换与人工神经网络模型，构建了基于残差分析的波动监测机制，适用于复杂非线性污染场景。

在预警策略进一步细化的趋势下，综合事件评估型触发机制开始受到关注。Li 等人^[54]提出了融合超标倍数、污染持续时间及影响范围的联合指标体系。Fernández-Ortega 等人^[55]构建了多层级响应模型，基于降雨、水位与污染物迁移特征划分预警等级。Wang 等人^[56]提出采用适应性阈值划分风险等级，制定分级响应方案。Naim 与 Bonaccorso^[57]则通过融合遥感与重分析气象数据，优化了复杂流域条件下的预警系统，在时效性与数据可靠性方面取得显著提升。

综上，水质预警机制正由单一指标触发、静态配置，逐步转向多源数据融合、动态分层响应的智能系统。未来研究应进一步聚焦高时空分辨率数据的协同应用、智能阈值自适应机制的构建与跨流域泛化模型的开发，以实现更高效、精准的水质预警体系。

1.3 研究目的与意义

近年来，流域水质管理面临模型表达能力提升与数据基础支撑不足的双重挑战。一方面，支流和中小河流的污染问题较为突出，污染过程在空间上具有强烈的异质性，在时间上呈现出显著的波动性。这对水质预测模型提出了更高要求，亟需具备空间感知能力与动态适应能力，以精准捕捉污染扩散路径与变化趋势，支撑精细化治理决策。另一方面，虽然生态监测与遥感技术的进步带来了更多可获取的数据资源，但在实际应用中仍面临三重困难：一是部分区域监测数据缺失或获取困难，影响了模型空间完整性；二是数据在来源、精度、时效性上的差异构成了典型的异构性问题；三是变量数量众多但机制不明，模型构建中易受到冗余干扰，

增加了解释难度与不确定性。在上述背景下，亟需构建一种融合多源信息、兼具精度与可解释性的流域水质预测与预警体系，以提升流域管理的科学性与响应效率。

针对上述挑战，本研究以赤水河（云南段）流域为研究对象，立足于其面源污染突出、治理资源有限的现实困境，以及生态保护和高标准水质目标的迫切需求，综合运用多源数据融合、人工智能算法优选、驱动因子识别等手段，聚焦以下研究目标：

（1）构建融合遥感、气象、水质与污染排放等多源数据的流域水质预测模型，提升复杂系统在多样数据条件下的建模能力与模拟精度；

（2）优化输入特征筛选方法，识别水质变化的关键驱动因子，增强模型的科学性与解释力；

（3）构建基于固定阈值法的水质预警机制，实现对高风险时段的及时响应与区域管理支持。

本研究的意义主要体现在以下四个方面：

（1）**丰富水质建模方法体系：**构建并比较基于 ANN 和 STGCN 的水质预测模型，验证引入空间结构后在提升预测精度与建模能力方面的优势，推动水环境模型向智能化和流域尺度发展。

（2）**提升模型可解释性与机理表达能力：**结合相关性分析与递归特征消除方法识别关键驱动因子，强化模型对污染过程的拟合能力与水质变化机理的表达，为数据驱动建模提供更强的理论基础与解释支撑。

（3）**支撑水质预警与管理决策：**构建基于固定阈值法的预警机制，实现关键污染物浓度的提前识别，为流域生态调度与污染防控提供响应时间和决策依据，兼顾生态安全与产业用水保障。

（4）**提供具推广性的建模技术路径：**探索遥感与气象等辅助数据在水质建模中的应用潜力，提出适用于区域环境管理的可复制、低成本的建模方案，具备实践推广价值。

1.4 研究内容与技术路线

本研究围绕构建兼具预测能力、解释能力与迁移能力的流域水质预测与预警技术体系，划分为以下三个研究模块：

（1）**时空数据集构建：**整合气象、水文、水质、污染排放与遥感影像等多源数据，开展系统的数据预处理与变量构建。针对气象、水文与水质数据，完成异常值

清洗、缺失值插补与时间精度统一；针对遥感数据，采用图像重投影、裁剪与质量控制等流程提取波段特征，并以网格为单位构建覆盖研究区的七维波段信息序列。在空间结构表达方面，基于子流域划分与河网信息构建空间加权邻接矩阵，为后续图神经网络建模提供支撑。最终形成包含时间序列特征与空间结构信息的高质量输入变量数据集。

(2) 基于 ANN 的河流水质时间预测预警模型构建与应用：选取气象、水文与水质等时间序列变量，采用相关性分析与递归特征消除方法筛选关键输入因子，构建 ANN 模型。模型训练阶段引入多组超参数组合进行优化，同时开展模型可解释性分析，明确各输入变量对预测结果的贡献。在实现高锰酸盐指数、氨氮、总磷和总氮等关键指标的逐日尺度预测后，依据国家地表水 II 类标准设定阈值，采用固定阈值法构建水质预警机制，实现对超标风险的动态识别，为流域管理提供决策参考。

(3) 基于 STGCN 的流域水质时空预测预警模型构建与应用：融合时间序列与空间结构特征，构建 STGCN 的水质预测模型。以气象、水质、污染排放和植被覆盖变量为基础，筛选关键输入因子，结合图结构信息进行建模。在训练与优化过程中，同步开展超参数调整与可解释性分析，提升模型对复杂时空依赖关系的感知能力。模型完成预测任务后，同样采用固定阈值法开展水质超标判别，实现预警功能，为水质调度与污染防治提供参考。在此基础上，开展跨子流域的迁移性分析，评估模型的泛化性能，验证其在流域尺度的适用性与推广潜力。

研究总体技术路线如图 1.1 所示：





图 1.1 研究技术路线图

第 2 章 数据驱动的流域建模与水质预警方法

2.1 案例区概况与数据来源

赤水河是长江上游重要的一级支流，全长约 445 公里，流域面积为 2.04 万平方公里，流经云南、贵州、四川三省。因河水含沙量高、呈赤黄色而得名，赤水河是我国唯一一条未建坝的长江干流支流，具有重要的生态屏障作用和生态保护价值。其水系发育良好，主要支流包括洛甸河、妥泥河和铜车河等。

赤水河流域孕育了以茅台、泸州老窖等为代表的酱香型白酒产业，是生态保护与区域经济协同发展的典范区域。云南段流域位于云南省昭通市境内，主要覆盖镇雄县和威信县，总面积约 1891.91 平方公里，占全流域面积的 9.3%，分别占两县国土面积的 38.25% 和 34.15%。该区域地形复杂，生态系统多样，河谷深切，水土流失严重，农业面源污染问题尤为突出。流域内布设 8 个地表水水质监测断面，覆盖干流与主要支流。2017 年土地类型以耕地（52.81%）和林地（41.30%）为主。



(a) 地理位置

(b) 河流水系

图 2.1 赤水河（云南段）流域地理位置、河流水系示意图

基于上述地理和生态特征，赤水河（云南段）流域作为国家重点生态功能区，

面临治理资源有限与生态保护压力共存的现实需求。《赤水河流域（云南段）生态环境保护与治理规划（2018-2030 年）》（以下简称《规划》）指出，该区域 16.7% 的土地受水土流失影响，面源污染和农业污染问题突出，部分断面存在总氮、总磷浓度连续超标的情况。在经济欠发达地区如镇雄、威信两县，受限于治理投入与基础设施条件，污染防控任务更为艰巨。同时，该区域上游水质状况对下游贵州仁怀市酱香型白酒产业构成重要影响，流域水质保障不仅关乎生态安全，也关系到下游产业用水安全和区域经济发展。

因此，亟需构建高效、科学的水质预测与预警机制，以提升流域污染响应能力与水质达标率，支撑生态与经济双重目标的实现。基于这一现实背景，本文选取赤水河（云南段）流域为研究区域，系统整合流域多源观测数据，开展水质预测模型构建与预警机制研究。

本研究所使用的气象数据、污染排放数据、水文观测数据及水质观测数据，均由昭通市相关政府部门提供，覆盖研究区域内多个水质监测断面及污染源点。为明确建模对象与空间覆盖范围，本文以《规划》中设定的 15 个地表水环境监测断面为基础，结合地理分布、数据完整性与模型构建需求进行筛选。剔除位置偏远或数据缺失严重的断面后，补充纳入邻近贵州省的清水铺断面，最终保留 14 个断面，具体信息见表 2.1。

在全部保留的 14 个监测断面中，仅“石坎”（断面 7）与“清水铺”（断面 16）拥有时间精度较高、数据连续性良好的水质观测数据，因此本文以这两个断面为建模对象，并统一数据时间精度为逐日。在综合考虑遥感、水文、气象、水质数据的可用性与时间对齐性后，最终选定研究时间范围为 2019 年 1 月 1 日至 2022 年 12 月 31 日，数据长度为 1461 天。

研究的目标水质变量包括逐日平均流量（Flow, Q ）、高锰酸盐指数（Permanganate Index, IMn）、氨氮（Ammonia, $\text{NH}_4\text{-N}$ ）、总磷（Total Phosphorus, TP）和总氮（Total Nitrogen, TN），后续模型将分别针对不同目标变量构建预测结构。

此外，为获取流域地表反射率的时空动态信息，遥感数据部分采用了美国国家航空航天局（NASA）提供的 MOD09GA.061 Terra Surface Reflectance Daily Bands 1-7 产品，数据获取自 NASA AppEEARS 平台^[58]。平台支持用户通过输入研究区域边界和时间范围筛选遥感图像，数据以 GeoTIFF 格式下载。后续处理通过 Python 脚本完成图像的批量预处理、掩膜、重投影与裁剪操作，最终形成可用于水质建模的多时相地表反射率序列。

表 2.1 赤水河流域地表水环境监测断面信息

断面 ID	断面名称	经度	纬度
1	洗白	104.8375	27.5147
2	笋坝河	105.0313	27.6808
3	住建局	105.0534	27.8184
5	两合岩	105.0744	27.8008
6	木屯寨扎西河干流处	105.0979	27.7746
7	石坎	105.1525	27.7858
8	花郎河	105.1584	27.7742
9	扎西河与赤水河交汇处	105.1800	27.7570
11	双河	105.2588	27.7935
12	水田渡口	105.2028	27.7754
13	湾沟村民委员会小河边	105.1830	27.5790
14	铜车河	105.2051	27.7357
15	笋河渡口	105.2844	27.7176
16	清水铺	105.5763	27.7195

表 2.2 研究所用主要数据清单

数据类型	数据描述	统计时间	数据精度
气象数据	国家级气象站监测数据	2000.01–2023.12	逐日
地形数据	数字高程数据（DEM）		30m 分辨率
遥感数据	MOD09GA.061 Terra Surface Reflectance Daily Bands 1–7	2019.01–2022.12	500m 分辨率；逐日
污染排放数据	污水处理厂运行参数	2019.01–2021.12	逐月
		2022.01–2022.12	逐日
水文观测数据	清水铺断面水文监测数据	2019.01–2022.12	逐日
水质观测数据	清水铺断面水质自动站监测数据	2018.03–2021.11	逐 4h
		2021.11–2022.12	逐 4h / 逐 1h
	石坎断面水质自动站监测数据	2011.01–2017.11	逐 2 月
		2021.01–2022.12	逐日

2.2 数据预处理方法

在获得原始数据后，常常面临缺失值、重复项及命名不一致等问题，因此需对其进行规范化处理，使其转化为适用于建模、训练与预测的可操作数据集。通常，数据预处理涉及六个主要环节：数据清理、数据集成、数据转换、数据规范化、特征选择与特征提取^[59-60]。其中，数据清理旨在识别并剔除异常值，同时填补缺失项；数据集成则通过整合多源数据，构建统一的数据体系；数据转换则针对数据的结构与格式进行调整，以满足模型处理的输入要求。这三类操作构成了数据预处理的基础。而数据规范化、特征选择与特征提取则依据具体研究目标，可在预处理阶段实施，也可能在建模阶段完成。本文将重点介绍在数据预处理阶段所采用的具体方法。

(1) ARIMA (AutoRegressive Integrated Moving Average) 插值法

为填补水质时间序列中存在的间歇性缺测段，本文采用 ARIMA 模型对不同季度的数据分别建模并进行插值预测。ARIMA 模型结合了自回归 (AR)、差分 (I) 与滑动平均 (MA) 三项结构特征，能够有效拟合非平稳单变量时间序列中的趋势变化与季节波动，因而在水文与环境类时间序列处理中具有较高适用性^[61-62]。

在具体建模过程中，首先对目标时间序列进行平稳性检验 (ADF 检验)，并根据检验结果判断是否需进行差分操作。对于不满足平稳性的序列，通过一阶或二阶差分对其进行平稳化处理，从而确定参数 d 。为进一步提高模型适配性并避免过拟合，本文在每个季度内单独拟合模型，并基于赤池信息准则 (AIC) 与贝叶斯信息准则 (BIC) 对备选模型进行评估，最终确定最优的模型阶数 (p, d, q) 。其中，AIC 和 BIC 均用于度量模型拟合误差与复杂度之间的平衡，其值越小代表模型综合表现越优。

参数选择过程中，本文对 p 和 q 的取值范围设定在 $[0, 5]$ ，结合网格搜索方式枚举不同组合，并基于 AIC/BIC 得分选取各季度序列的最优模型结构。最终选定的模型用于估算缺失点的未来或过去值，并作为插值结果填补空缺。

ARIMA 模型的一般形式如下所示：

$$\phi(B)(1 - B)^d x_t = \theta(B)\varepsilon_t \quad (2.1)$$

式中， x_t ——时间 t 时刻的观测值；

B ——滞后算子，即 $B^k x_t = x_{t-k}$ ；

$\phi(B)$ ——自回归项多项式， $\phi(B) = 1 - \phi_1 B - \dots - \phi_p B^p$ ；

$\theta(B)$ ——滑动平均项多项式， $\theta(B) = 1 + \theta_1 B + \dots + \theta_q B^q$ ；

ε_t ——白噪声扰动项，均值为 0，方差为 σ^2 。

预测缺失值时，通过估计其在当前与历史扰动条件下的期望值实现插补：

$$\bar{x}_t = E(x_t | x_{t-1}, x_{t-2}, \dots, \varepsilon_{t-1}, \varepsilon_{t-2}, \dots) \quad (2.2)$$

考虑到赤水河流域水质指标在不同季度存在显著的变化规律，若对全年序列整体建模易掩盖局部特征，本文在季度尺度下分别建模，有助于更精准地捕捉局部时段的趋势特征，提高缺失段插值精度。




图 2.2 ARIMA 模型插值流程图

(2) SG 滤波器法 (Savitzky-Golay Filter)

为在平滑水质时间序列的同时保留其真实变化趋势，本文引入 Savitzky-Golay (SG) 滤波器对原始观测值进行平滑插值。SG 滤波器通过在局部滑动窗口内以最小二乘法拟合多项式，有效剔除高频扰动，在不显著改变原始波形的前提下实现对缺失段的插值修复^[63-64]。

建模时，本文依据赤水河流域逐日尺度水质数据特性，发现其整体变化缓慢但存在局部波动，因而不宜采用全局趋势模型进行插补。为更合理地处理这类局部扰动与短缺段数据，本文选用 SG 滤波器在缺失段前后构建局部窗口，对其进行一阶或二阶多项式拟合，并提取中心点作为估计值。窗口长度 $2M + 1$ 和多项式阶数 N 的设置通过实验评估确定，以兼顾平滑效果与趋势保留。

其核心思想如下：给定以 $n = 0$ 为中心的 $2M + 1$ 个数据点，在该窗口内构建 N 阶拟合多项式：

$$p(n) = \sum_{k=0}^N a_k n^k \quad (2.3)$$

式中， $p(n)$ ——多项式在 n 的拟合结果；

a_k —— 多项式系数;

N —— 多项式最大阶数。

通过最小化下式残差求解系数:

$$\varepsilon = \sum_{n=-M}^M \left(\sum_{k=0}^N a_k n^k - x[n] \right)^2 \quad (2.4)$$

式中, ε —— 残差;

$x[n]$ —— 位置 n 处的原始观测值;

M —— 窗口半宽, 即拟合区间左右两侧数据点数量。

为求解使残差最小的系数组, 需满足:

$$\frac{\partial \varepsilon}{\partial a_i} = \sum_{n=-M}^M 2 \left(\sum_{k=0}^N a_k n^k - x[n] \right) n^i = 0 \quad (2.5)$$

整理得正规方程组:

$$\sum_{k=0}^N \left(\sum_{n=-M}^M n^{i+k} \right) a_k = \sum_{n=-M}^M n^i x[n] \quad (2.6)$$

式中, i —— 多项式阶数, $i = 0, 1, \dots, N$ 。

引入辅助矩阵 $A \in \mathbb{R}^{(2M+1) \times (N+1)}$, 其元素为:

$$A = \{a_{n,i}\} = \{n^i\} \quad (2.7)$$

式中, n —— 窗口内位移, $n \in [-M, M]$;

i —— 幂次索引, $i \in [0, N]$ 。

进一步定义矩阵 B :

$$B = A^T A, \quad \beta_{i,k} = \sum_{n=-M}^M n^{i+k} = \beta_{k,i} \quad (2.8)$$

最终建立线性方程组:

$$Ba = A^T x \quad (2.9)$$

式中, a —— 拟合系数列向量, $a = [a_0, a_1, \dots, a_N]^T$;

x —— 窗口内原始观测数据, $x = [x[-M], \dots, x[M]]^T$ 。

从而解得：

$$a = (A^T A)^{-1} A^T x = Hx \quad (2.10)$$

式中， H ——平滑系数矩阵，仅与 M 与 N 的设置有关。

由于 SG 滤波具有在保留数据主要变化趋势的同时平滑局部波动的特性，本文将其用于水质监测数据中的异常值识别与清洗。具体操作中，对原始序列进行滑动窗口拟合，并将中心点拟合值与原值之间的差值与阈值进行比较，识别出偏离程度较大的异常观测值。被识别的异常值随后以 SG 滤波的拟合结果进行替换，从而在不破坏总体趋势的前提下提高数据质量。该方法特别适用于日尺度数据中由于设备误差或突发环境变化导致的孤立异常点，确保后续模型输入的稳定性 and 预测准确性。

2.3 变量筛选与重要性评估方法

在数据驱动的水质建模中，变量的科学筛选对于提升模型精度与解释性具有重要意义。由于环境因子间存在复杂的交互作用及区域异质性，单一评估方法难以全面衡量各输入变量的重要性。因此，本文结合多种方法开展关键变量识别工作，确保筛选结果的稳健性与可靠性。

具体而言，在建模过程中，本文分别在两个关键场景中使用了变量筛选方法：其一，用于识别与水质变化高度关联的关键气象站点，明确建模所需的输入来源；其二，用于构建人工神经网络与图神经网络模型前的输入变量优选，提升模型的泛化能力与预测效率。为兼顾变量间的线性与非线性关系，并提升筛选策略的综合表现，本文采用了相关性分析、多元回归分析与基于随机森林的特征重要性评估三种方法联合进行变量优选。

2.3.1 相关性分析

本文首先使用 Pearson 相关系数（适用于线性关系）与 Spearman 相关系数（适用于单调非线性关系）评估气象变量（最高气温、最低气温、相对湿度、风速、日照时数、降水量）与水文水质变量（流量、高锰酸盐指数、氨氮、总磷、总氮）之间的相关性，识别候选变量集合。对于气象站筛选，通过计算各气象站与水质因子的相关性绝对值均值并排序，作为初步筛选依据；在特征选择阶段，也利用该方法识别出对目标变量变化最为敏感的一组输入特征。

Pearson 相关系数:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}} \quad (2.11)$$

Spearman 相关系数:

$$r_s = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)} \quad (2.12)$$

式中, d_i ——排名之差;

n ——样本数。

2.3.2 多元线性回归分析

为进一步定量评估各变量的影响力, 本文采用多元线性回归 (Multiple Linear Regression, MLR) 模型分析各气象站变量与水质因子的线性拟合效果, 并以平均 R^2 作为衡量标准选出最优站点。

模型表达式如下:

$$Y = \beta_0 + \sum_{i=1}^p \beta_i x_i + \varepsilon \quad (2.13)$$

式中, Y ——目标变量;

x_i ——第 i 个输入变量;

β_i ——回归系数;

ε ——误差项。

2.3.3 随机森林变量重要性评估

为克服线性模型对变量间非线性关系识别能力的限制, 本文进一步采用随机森林 (Random Forest, RF) 模型评估变量重要性。该方法基于多个决策树的集成学习, 能够较为准确地识别输入特征中对预测目标贡献最大的变量, 同时对异常值与多重共线性具备一定鲁棒性。

在气象站筛选阶段, RF 用于验证线性回归与相关性分析识别出的最优站点在非线性建模下的稳定性; 在人工神经网络模型建模过程中, 本文将 RF 的特征重要性评分作为递归特征消除 (Recursive Feature Elimination, RFE) 的依据, 对输入特征进行进一步筛选。

变量重要性计算表达式如下:

$$VI(x_i) = \sum_T I_t \cdot \Delta Gini_t \quad (2.14)$$

式中, $VI(x_i)$ ——变量 x_i 的重要性;
 T ——所有树的集合;
 I_t ——该变量是否被用于节点划分;
 $\Delta Gini_t$ ——使用该变量所带来的基尼指数减少量。

此外, 本文亦在模型训练完成后, 对关键输入变量的影响机制进行解释分析时再次使用了该方法。第四章中采用相同的随机森林模型结构与特征重要性计算方式, 对 ANN 模型的输入特征进行可解释性评估。通过归一化后的变量重要性得分, 可以识别出对模型预测影响最大的前若干变量, 为后续结果解读与管理决策提供支持。该方法具备良好的稳定性与可迁移性, 能够贯穿于变量筛选与模型解释的全过程。

2.4 基于机器学习的水质预测方法

2.4.1 人工神经网络

人工神经网络 (Artificial Neural Network, ANN) 是一类受生物神经元启发的非线性建模方法, 通过多层神经元结构对输入特征进行组合和映射, 适用于回归与分类等多种任务。在环境领域, ANN 模型已被广泛应用于水质指标预测、水体分类等问题中。

神经元模型最早由 McCulloch 和 Pitts 于 1943 年提出, 其数学表达如下:

$$y = f \left(\sum_{i=1}^n \omega_i x_i + b \right) \quad (2.15)$$

式中, y ——神经元输出;
 x_i ——输入特征, 第 i 个输入;
 ω_i ——对应的连接权重;
 b ——偏置项;
 $f(x)$ ——激活函数。

神经网络通过多层神经元堆叠, 形成输入层、若干隐藏层及输出层结构。其中隐藏层为模型学习非线性映射能力的核心部分, 各层之间采用全连接结构, 层内神经元之间不发生信息传递。

在本文研究中, ANN 模型用于构建水质时间序列的预测模型。模型结构设计方面, 考虑到输入变量维度、数据量与非线性拟合需求, 最终采用包含三层隐藏层

的前馈神经网络结构。模型中引入了残差连接（Residual Connection）以增强中间特征的表达能力，使用 PReLU 激活函数和 BatchNormalization 规范化层以提高训练稳定性，并通过 Dropout 抑制过拟合风险。

模型训练过程中，采用 7:1.5:1.5 的比例划分训练集、验证集与测试集，通过早停机制（Early Stopping）与学习率调度（ReduceLROnPlateau）控制训练过程。为进一步提升模型表现，设计了多个隐藏层宽度（如 256-256-128，512-512-256）与不同丢弃率的组合实验，最终选取综合指标表现最优的参数结构作为最终模型。

ANN 模型在本文中主要承担回归预测任务，根据历史时间序列数据对目标变量（如高锰酸盐指数）进行建模与预测，结果显示其在捕捉短期趋势与周期性变化方面具有良好表现。

2.4.2 时空图卷积网络

传统 ANN 模型主要面向时间序列建模，难以有效捕捉具有空间依赖性的环境变量之间的动态关系。为充分利用流域空间结构及其变化特征，本文引入时空图卷积网络（Spatial-Temporal Graph Convolutional Network, STGCN）对水质数据进行建模。STGCN 模型由 Yu 等人于 2018 年提出，具备同时提取空间邻接结构和时间演化特征的能力，在交通、气象、水文等领域得到广泛应用^[65]。

在 STGCN 模型中，水质监测断面被抽象为图结构中的节点，节点之间的边由地理邻近性或水文连通性定义构建，从而形成图 $G = \{V, E, A\}$ ，其中 V 为节点集合， E 为边集合， A 为邻接矩阵。随着时间的推进，每一个时刻构成一幅图，依时间顺序形成时空图数据结构，如图 2.3 所示^[65]。




图 2.3 时空图结构示意图^[65]

STGCN 网络主要由三个部分组成：空间卷积模块、时间卷积模块以及残差连接模块。空间卷积部分用于对节点邻域的信息进行聚合，建模空间相互作用；时间卷积部分通过滑动窗口提取节点属性在连续时间序列中的演化特征；残差模块用于提高特征在网络中的流动性并缓解深层网络训练中的梯度问题。图卷积部分采

用 Chebyshev 多项式对图拉普拉斯算子进行近似，提升了计算效率和模型可扩展性。时间模块则采用门控卷积单元（Gated Linear Unit, GLU），替代传统循环结构，增强训练稳定性。

在模型设计中，本文结合赤水河流域的空间地理信息，依据子流域河网距离与汇流路径构建邻接矩阵，使图结构能真实反映断面间的地理与水文关系。节点的输入特征融合了遥感波段、气象数据与污水排放因子等异质信息，确保模型在空间维度上具备多源特征感知能力。

在建模过程中，考虑到水质指标不仅受自身历史值影响，还受到上游输入、降雨、土地利用类型等空间驱动因子的影响，若仅使用时间序列模型可能无法充分反映这种多维依赖性。为此，本文选用 STGCN 构建预测模型，并在网络结构设计中综合考虑空间邻接方式与特征维度，对比不同卷积核大小与层数配置，最终选取预测性能最优的模型组合。时间模块中采用 GLU 结构以提升长序列建模时的训练效率与稳定性，避免梯度消散等问题。

STGCN 最终能够在多源数据融合的基础上，捕捉到流域内部的非线性时空依赖关系，并提升模型对水质变化趋势的预测能力。如图 2.4 所示，模型结构由多个时空卷积单元堆叠组成，具备端到端的学习能力。




图 2.4 STGCN 模型结构图^[65]

2.5 模型评估方法

为全面衡量水质预测模型的性能表现，本文选取决定系数（ R^2 ）、均方根误差（RMSE）、平均绝对误差（MAE）以及平均绝对百分比误差（MAPE）四类常用评估指标。上述指标可从多个角度评估模型预测值与观测值之间的拟合程度与偏差情况，有助于综合判断模型的精度、稳定性与泛化能力。

其中， R^2 表示预测结果对观测数据变异的解释程度，值越接近 1 表明拟合效果越佳；RMSE 强调大偏差的惩罚效果，适用于捕捉模型在异常值处的误差放大情况；MAE 反映预测值与观测值的平均绝对差值，单位与原变量一致，直观体现误差水平；MAPE 为无量纲指标，可跨变量类型衡量预测误差的相对水平。相关研究表明，结合这几项指标可全面评价模型在环境预测任务中的表现^[20,66-67]。

四项指标的计算公式如下所示：

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (2.16)$$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (2.17)$$

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (2.18)$$

$$\text{MAPE} = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \quad (2.19)$$

2.6 预警机制与方法

在水质预测建模的基础上，科学构建预警机制对于流域环境风险管理与污染防控具有重要意义。本文选取固定阈值法（Fixed Threshold Method）作为预警机制的实现路径，以实现重点断面污染风险的直观判别与可操作识别。

固定阈值法是一种常用的基于标准限值判断是否超标的方法，其核心思想是：将总氮（TN）、总磷（TP）、氨氮（ $\text{NH}_4^+\text{-N}$ ）、高锰酸盐指数（IMn）等目标变量的预测结果与既定限值进行比较，当任一指标预测值超过相应阈值，即触发预警信号，提示潜在水质风险。该方法具备操作简便、计算效率高、结果易于解释等优势，尤其适用于基于单断面预测结果的基础预警判断。

赤水河（云南段）流域虽整体水质较好，但仍存在一定的面源污染风险；同时，《规划》中明确提出以达到地表水 II 类水质标准为目标。基于此，案例区亟需一种轻量化、标准导向清晰的预警机制。相比于复杂的动态判别或智能阈值方法，固定阈值法能够更直接地判断预测结果是否满足 II 类水质要求，便于管理部门快

速响应，契合当前流域的实际治理需求。

阈值的确定可依据国家环境标准或区域管理目标。本文结合《规划》的管理要求，阈值设定参考了《地表水环境质量标准》（GB 3838-2002）中 II 类水质限值，如表 2.3 所示。

表 2.3 地表水水质 II 类标准限值

水质指标	限值（单位：mg/L）
高锰酸盐指数 IMn	4.0
氨氮 $\text{NH}_4^+\text{-N}$	0.5
总磷 TP	0.1
总氮 TN	0.5

在建模阶段，本文将各目标变量的最优模型预测值与上述阈值进行对比，实现逐日尺度的水质预警判断。该方法具备良好的可拓展性，后续亦可在此基础上叠加趋势分析、复合指标评估等多元机制，进一步提升预警系统的实用性与前瞻性。

2.7 本章小结

本章围绕研究区域的基本情况与数据预处理方法展开说明，明确了模型构建所依赖的核心技术路径。首先，选取赤水河（云南段）流域作为研究对象，基于流域水质、水文、气象、遥感和污染排放等多源观测数据，构建了清水铺与石坎两个具有代表性的建模断面。针对原始数据存在的缺失与异常问题，分别引入 ARIMA 插值与 Savitzky-Golay 滤波器进行补全与平滑，提升了时间序列的完整性与可信度。在空间数据方面，完成了 MOD09GA 遥感产品的质量控制、裁剪与波段提取，建立了高时空分辨率的多变量输入特征集，为模型提供全面的信息支撑。

在建模方法准备方面，本文结合环境变量的非线性演化特征与空间结构依赖性，预设采用 ANN 与 STGCN 两类模型。前者适用于时间序列预测任务，后者则能够捕捉断面间复杂的空间交互关系。在特征选取阶段，通过相关性分析、多元线性回归与随机森林三种方法联合筛选输入变量，提升了模型的稳健性与泛化能力。模型评估则统一采用 R^2 、RMSE、MAE 和 MAPE 四类指标，从多个角度评估预测精度。与此同时，构建基于国家地表水 II 类标准的固定阈值预警机制，用于识别超标风险。上述方法为后续模型构建、对比分析与预警响应奠定了坚实基础。

第 3 章 时空数据集构建

为提升流域水质预测模型的泛化能力与结构稳定性，构建标准化、具物理意义的时空数据集至关重要。鉴于赤水河流域监测站点在空间分布与观测精度方面差异较大，本章围绕清水铺与石坎两个典型断面，系统开展数据预处理与空间结构构建工作。

首先，对水质、水文、气象与污染排放数据进行质量控制与缺失值填补，采用 SG 滤波与 ARIMA 插值法提升时间序列的完整性与连续性。随后，处理 MODIS 遥感数据，生成 500m 分辨率的地表反射率时间序列，并通过 QA 掩膜与空间插值获取高质量植被覆盖特征。

在空间建模方面，结合 DEM 与河网数据划分子流域，并基于坡面流向与河道传播路径构建物理解释力强的空间加权邻接矩阵。同时，设计多步骤变量评估流程，识别对水质变化驱动作用显著的气象站点，为后续模型提供代表性输入基础。

3.1 气象、污染排放、水文、水质数据预处理

由于水质、气象等数据多来自自动监测站，易受到传感器漂移、采样异常等因素干扰，导致数据中存在孤立异常值或噪声干扰。为提高模型对时间序列模式的学习能力，本文采用 SG 滤波器对原始水质序列进行平滑处理，在保留长期趋势特征的同时有效剔除高频扰动，从而提升数据质量与建模稳定性。

针对水质数据中存在的间断缺失问题，本文选用 ARIMA 模型进行插值补全。考虑到部分水质指标呈现明显的季节周期性，建模过程中将全年序列按季度分段处理，以提高插补精度与局部拟合效果。对于石坎断面在 2019-2020 年间存在整年缺失，采用 2021-2022 年数据按季度建模，并预测相应时间段的缺失值，从而实现长时段数据的连续重建。

3.2 遥感数据预处理

使用 NASA 提供的 MOD09GA.061 Terra 表面反射率产品（Level-2G），从 Earthdata 平台通过 AppEEARS 接口（<https://appeears.earthdatacloud.nasa.gov>）获取遥感数据。该产品已完成辐射定标、几何与大气校正，具有 500 m 空间分辨率，覆

盖红光、近红外与短波红外波段，适用于 NDVI 计算和土地利用分类（见表 3.1）。

表 3.1 波段的波长范围与典型用途

波段编号	波长范围（ μm ）	主要用途
Band 1	0.620–0.670	红光，用于植被与土壤识别
Band 2	0.841–0.876	近红外，用于 NDVI 与植被监测
Band 3	0.459–0.479	蓝光，大气校正、云检测
Band 4	0.545–0.565	绿光，用于植被分类
Band 5	1.230–1.250	近红外，监测植被含水量与覆盖变化
Band 6	1.628–1.652	近红外，识别云/雪与干旱地物
Band 7	2.105–2.155	短波红外，识别植被结构与覆盖退化

针对赤水河流域研究区，首先依据其矢量边界对遥感影像进行空间裁剪，并统一投影至 WGS84 地理坐标系，以确保坐标系统一致性与空间对齐精度，避免因投影差异导致的空间偏移与定位误差。随后，以 500 m 空间分辨率构建分析网格，提取各网格单元中心点的经纬度坐标，作为空间定位的依据及环境变量提取的空间参考，为后续数据融合与建模分析提供统一的空间框架支撑。

在数据质量控制方面，本研究基于 MOD09GA 产品中提供的地表反射率质量控制信息（Surface Reflectance Quality Assurance, QA），使用 QC_500m_1 层对数据进行质量掩膜处理。该质量层采用二进制编码记录每个像元的质量信息，包括云覆盖、阴影、积雪、气溶胶水平等干扰因素。通过解码该层信息，可有效筛选受干扰像元，保留高质量的观测数据，从而构建可信度较高、连续性良好的遥感反射率时间序列。在此基础上，提取波段 1 至 7 的日尺度反射率值，生成覆盖研究区域的 500 m 分辨率时间序列数据集，用以表征植被覆盖的时空演变特征，为环境响应分析与后续变量构建奠定坚实的数据基础。

针对遥感数据集存在的缺失值问题，采用两阶段缺失值填补策略进行修复：第一阶段，对局部时刻缺失的像元，采用双向线性插值法进行时间维度插补，增强序列的连续性与稳定性；第二阶段，对于某些日期上存在整块缺测的网格单元，选取其空间上临近的 K 个最近邻有效网格，在同一日期下计算其反射率的平均值，作为该缺失值的替代。这一策略在兼顾时间连续性与空间相似性的基础上，有效提升了时间序列数据的完整性与可用性，为高质量的模型输入数据提供了坚实保障。

3.3 流域植被覆盖信息提取

为克服纯数据驱动模型在流域水文建模中对物理机制考虑不足的问题，尤其在流域拓扑结构识别方面缺乏机制性约束，易导致预测结果与实际水文过程脱节，本文借鉴 SWAT 模型的子流域划分思路，以子流域作为基本建模单元开展模型训练。该策略有助于增强模型对流域水文地理特征的响应能力，提升所提取特征在空间上的水文一致性与物理可解释性，为实现区域尺度下的水质模拟与管理提供了方法支持。

本研究基于数字高程模型（DEM）与水文地形分析方法进行子流域划分。首先，利用流向分析（Flow Direction）计算每个栅格单元的水流方向，并通过累计流量分析（Flow Accumulation）识别潜在的水流主干道。结合已有河网数据，在主要河流交汇处、监测断面或研究关注区域设置汇水点（Pour Points），并通过阈值筛选确定其代表性径流路径。随后，采用流域分割（Watershed Delineation）方法，基于汇水点实现子流域自动划分，使每个子流域作为相对独立的汇水单元，具备良好的水文边界属性。最终，将研究区域划分为 33 个子流域（如图 3.1 所示），其网格数量与包含监测断面信息详见表 3.2。其中，子流域 21 因面积过小，在 500 m 分辨率下未覆盖任何栅格单元。



图 3.1 研究区域子流域示意

表 3.2 子流域网格划分

子流域 ID	网格数量	子流域内站点
1	591	无
2	302	无
3	294	无
4	308	无
5	402	双河乡养殖场
6	337	无
7	766	住建局，两合岩
8	157	双河
9	12	水田渡口
10	350	木屯寨扎西河干流处，石坎，花郎河
11	88	扎西河与赤水河交汇处
12	379	无
13	301	无
14	286	清水铺
15	222	岔河渡口
16	1273	无
17	488	无
18	337	无
19	529	无
20	43	无
21	0	无
22	327	无
23	44	岔坝河
24	33	无
25	310	无
26	417	铜车河
27	380	无
28	61	无

续表 3.2 子流域网格划分

子流域 ID	网格数量	子流域内站点
29	316	无
30	310	无
31	1269	洗白
32	1663	无
33	1096	湾沟村民委员会小河边

为准确刻画研究区内各网格对下游水质断面的潜在影响路径，本研究结合坡面流向与河网拓扑结构，引入复合水文距离指标构建空间加权邻接关系矩阵。该方法以水文过程为基础，相较传统欧氏距离加权方法，能更真实地反映水流在地形约束下的自然汇流路径与污染物迁移过程，具备更强的物理意义与水文解释力，有助于提升模型对空间异质性的表达能力。本方法主要适用于石坎断面（子流域 10）与清水铺断面（子流域 14），确保不同断面处理方式的一致性与科学性，从而增强跨区域建模的适用性与推广价值。

具体操作上，首先基于高分辨率 DEM 数据对研究区进行洼地填平（Depression Filling）与坡面流向分析（采用 D8 算法），建立地势控制下的水流路径模型。随后，基于矢量河网数据提取主干河道并栅格化处理，将其作为水流汇入终点，利用 WhiteboxTools 中的 downslope distance to stream 工具，计算各网格中心点沿坡面流向至主干河道的最短水文路径距离，记作 D_s 。该距离表示雨滴自网格单元出发自然汇流至河道的最短路径长度，具有明确的水文物理意义，可视为地表径流路径的近似表征。

同时，为反映沿河网网络结构从汇流点到目标断面（如石坎或清水铺）之间的水流传播过程，本研究进一步基于河网拓扑结构与断面坐标，采用定向路径追踪方法而非传统最短路径算法，计算其河道传输距离，记作 D_r 。二者叠加即形成每个网格点对目标断面的“完整水文路径”，即总距离，记作 D_{total} 。用于度量污染物从源区输送至监测点的水文驱动强度与传播潜力。

$$D_{total} = D_s + D_r \quad (3.1)$$

其中， D_{total} ——总距离；

D_s ——坡面流向距离；

D_r ——河网传输距离。

为避免远距离网格对水质预测断面产生非实际性影响，本研究引入指数衰减函数对总距离进行加权，构建空间邻接关系矩阵。其权重计算公式如下：

$$\omega_i = \exp\left(-\alpha \cdot \frac{D_{\text{total},i}}{D_{\text{max}}}\right) \quad (3.2)$$

其中， $D_{\text{total},i}$ ——第 i 个网格的总距离；

D_{max} ——研究区内的最大总距离，用于归一化处理；

α ——衰减系数，设定为 3，用以增强对距离变化的敏感性。

该加权方式体现了“近影响强、远影响弱”的水文传播特征，符合水流动能衰减与污染物稀释扩散的自然规律。最终，空间邻接关系以边列表（Edge List）形式输出，便于后续图神经网络模型调用，同时兼顾数据结构的紧凑性与计算效率。

3.4 关键气象站识别

为提升建模效率并提高气象输入变量的代表性，本文在建模前对研究区主要气象站进行了系统评估。具体流程遵循“相关性初筛—线性回归精筛—非线性模型验证”的顺序展开，兼顾变量之间的线性与非线性关系，确保识别结果的科学性与稳健性，从而提升模型输入层的物理含义与泛化能力。

首先，采用相关性分析计算各气象站主要气象变量与水质因子的相关性均值，筛选出表现最优的三个候选站点；随后，利用多元线性回归模型（MLR）拟合各站点气象因子与目标水质变量之间的线性关系，进一步甄别拟合效果最佳的站点；最后，引入随机森林模型对全部站点进行变量重要性评估，检验最优站点在非线性的建模情境下的重要性是否依旧显著，从而完成全流程识别。该方法组合集成了统计分析的可解释性与机器学习模型的表达能力，充分平衡了准确性与通用性，为模型输入变量提供了坚实支撑与可靠保障。

结果显示，在清水铺断面中，镇雄站、威信站和古蔺站在相关性分析中排名靠前，进一步的 MLR 模型表明威信站具有更好的拟合能力，而随机森林分析也显示其在所有站点中变量重要性最高，验证了其作为主要驱动因子的稳定性（见表 3.3）。

在石坎断面，三种方法所得结果高度一致。叙永站在相关性、拟合能力及变量重要性三方面均优于其他站点，显示其为与石坎断面水质响应关系最强的气象站（见表 3.4）。

表 3.3 清水铺断面关键气象站识别结果

气象站	平均相关性	平均 R^2 值	变量重要性
镇雄站（56595）	0.1541	0.1352	0.2661
威信站（56596）	0.1549	0.1584	0.2903
古蔺站（57605）	0.1688	0.1554	0.2124
叙永站（57608）	0.1457	——	0.0723
毕节站（57707）	0.1292	——	0.1589

表 3.4 石坎断面关键气象站识别结果

气象站	平均相关性	平均 R^2 值	变量重要性
镇雄站（56595）	0.2121	——	0.1425
威信站（56596）	0.2432	——	0.1764
古蔺站（57605）	0.2481	0.2025	0.1861
叙永站（57608）	0.2528	0.2173	0.3094
毕节站（57707）	0.2526	0.2106	0.1855

3.5 本章小结

本章围绕水质预测建模所需的多源异构输入数据，系统完成了赤水河流域典型断面所需的时空数据集构建任务。首先，明确研究对象与时间范围，并对水质、水文、气象、污染排放与遥感数据进行质量控制与插补修复；SG 滤波与 ARIMA 插值方法协同使用，分别应对高频噪声与长时缺失段，显著提升了数据连续性与可用性。

其次，遥感数据经过 QA 掩膜、重投影与空间插值处理，构建日尺度、空间分辨率为 500m 的反射率时间序列，为后续植被覆盖动态分析提供基础。在空间结构方面，结合 DEM 与矢量河网划分 33 个子流域，并依据坡面流向与河道传播路径构建空间加权邻接矩阵，增强数据结构对水文地理过程的响应能力，为图神经网络模型提供了结构合理的输入框架。

此外，为提升气象输入维度的代表性，建立了多方法融合的关键气象站识别流程。识别结果显示，威信站、叙永站分别为与清水铺、石坎断面水质响应关系最强的气象站。三种方法在两个断面上结果高度一致，验证了方法的稳定性与通用性。

本章构建的标准化数据集不仅具备较强的时空表达能力与水文物理意义，也为后续章节中的建模任务提供了输入支撑。所提出的处理与识别流程具有较强的可移植性，可推广应用于其他流域的数据集构建与变量筛选场景中。

第 4 章 基于 ANN 的河流水质时间预测模型构建与应用

为提升河流水质监测的时效性与预警能力，本章构建了基于 ANN 的水质时间预测与预警模型。研究以赤水河流域云南段的清水铺断面为例，整合气象、水文与水质多源时序变量，经过变量筛选和模型超参数调优，建立了多目标预测模型，并在训练集与测试集上评估其拟合能力与泛化表现。

此外，为提升模型的透明性与实用性，本章进一步开展特征重要性分析，明确不同输入变量对预测结果的贡献，并基于国家地表水 II 类标准构建固定阈值法水质预警机制，探索模型在污染监测与风险预警中的实际应用潜力。

4.1 关键输入变量识别

河流水质时间预测预警模型仅考虑时间特征的输入变量，包括气象、水文和水质变量（见表 4.1）。清水铺断面位于研究区域的最下游，能够反映上游整个流域的水质状况，且其水质监测数据精度高、缺失较少，适合作为建模样本。虽然 ANN 具备一定特征自动学习能力，仍引入变量筛选旨在提升模型收敛效率与泛化性能。

本研究采用两阶段变量筛选策略：第一阶段通过 Pearson 相关性分析初筛变量；第二阶段引入以随机森林为基础的递归式变量剔除算法（Recursive Feature Elimination, RFE），进一步识别对目标变量具有稳定贡献的变量。在整合相关性、RFE 排名与变量物理意义的基础上，最终确定各目标变量的最优输入集（见表 4.2）。

表 4.1 未经选择的输入变量

变量类型	变量数量	变量名称
气象变量	6	最高气温、最低气温、相对湿度、风速、日照时数、降水量
水文变量	2	逐日平均流量、逐日平均含沙量
水质变量	9	水温、pH、溶解氧、浊度、电导率、高锰酸盐指数、氨氮、总磷、总氮

表 4.2 输入变量选择结果

目标变量	输入变量
逐日平均流量 Q	逐日平均流量、逐日平均含沙量、降水量、水温、高锰酸盐指数、日最低气温、总氮、总磷、溶解氧、pH
高锰酸盐指数 IMn	高锰酸盐指数、总磷、氨氮、逐日平均含沙量、总氮、溶解氧、pH、平均风速、水温、平均相对湿度
氨氮 $\text{NH}_4^+\text{-N}$	氨氮、总磷、总氮、高锰酸盐指数、pH、平均风速、溶解氧、水温、日最低气温、逐日平均含沙量
总磷 TP	总磷、总氮、氨氮、高锰酸盐指数、逐日平均含沙量、溶解氧、水温、pH、平均风速、日最低气温
总氮 TN	总氮、总磷、氨氮、pH、逐日平均含沙量、高锰酸盐指数、溶解氧、水温、日最低气温、日最高气温

4.2 河流水质时间预测模型构建

本研究针对逐日平均流量、高锰酸盐指数、氨氮、总磷和总氮五个目标变量，构建了 ANN 模型，以实现河流水质的时间预测。模型的输入层包含多个特征变量，其中包括时间特征（如星期几、月份、季度）以及滞后特征（1 天、2 天、3 天、7 天、14 天、30 天的降雨滞后值）。为了减少冗余性并提高计算效率，本研究采用了随机森林方法评估变量的重要性，筛选出对预测效果影响较大的变量，从而优化模型性能并提高计算效率。

为确保数据的稳定性和消除噪声，本研究对输入数据进行了归一化处理。具体地，采用 MinMaxScaler 方法将数据缩放至 [0,1] 区间，以确保各变量在相同的尺度范围内，避免因量纲不同而影响模型训练效果。此外，对于降水量、浊度等偏态数据，应用 Box-Cox 变换与对数变换（Log Transform），以减少数据分布的偏斜，进一步提高 ANN 在学习过程中的稳定性^[68]。

ANN 模型结构采用三层隐藏层设计。第一、二层使用 PReLU (Parametric ReLU) 激活函数，引入批量归一化 (Batch Normalization) 加速训练并提高稳定性，并采用适当的丢弃率 (Dropout) 以缓解过拟合。在第二层后引入残差连接 (Residual Connection)，确保梯度在深层网络中的有效传播。研究表明，2 至 3 层的 ANN 结构在水文时间序列预测中表现良好，而 ReLU 激活函数有助于缓解梯度消失问题^[69]。第三层神经元数量为第一层的一半，采用 ReLU 激活函数与丢弃率联合设计。

在损失函数的设置上,本文选用 log-cosh 损失函数。该函数在误差较小时与均方误差 (MSE) 近似,但在面对离群值时具有更强的鲁棒性,可有效减弱异常值对模型训练过程的干扰。优化算法采用 Adam (Adaptive Moment Estimation, 自适应矩估计) 优化器,初始学习率设定为 0.001。为提升训练效率与模型稳定性,引入了学习率自适应调整机制 (ReduceLROnPlateau): 当验证集损失在连续 5 个训练轮次 (epoch) 内未见下降时,自动将学习率降低 30%,并设置最低学习率为 10^{-5} 。同时,采用提前停止机制 (Early Stopping),若验证损失在 15 个 epoch 内无明显改善,则终止训练,并回滚至性能最优的模型权重^[70]。训练的最大轮次数设置为 300,批次大小 (batch size) 为 64。模型性能评估采用决定系数 (R^2)、均方根误差 (RMSE)、平均绝对误差 (MAE)、平均绝对百分比误差 (MAPE) 四项指标,用以综合衡量不同超参数组合下的预测精度与稳定性。模型训练采用逐步递归预测方式,即基于 $t-1$ 天及更早数据预测第 t 天的目标变量,确保预测的前瞻性与合理性。

由于不同水质参数的时序特性差异较大,ANN 模型的最优结构与超参数组合也可能存在不同。因此,本研究特别设计了两组隐藏层组合 ((256, 256, 128) 与 (512, 512, 256)),每组配合四种丢弃率 (0.0, 0.1, 0.2, 0.3) 进行对比,以识别最优超参数设置。

在不同超参数组合下,ANN 模型的预测性能存在差异。本研究针对不同目标变量,优化了隐藏层神经元数量和丢弃率。表 4.3 展示了不同目标变量在不同超参数组合下的模型性能变化情况。进一步地,表 4.4 总结了各目标变量在最优预测性能下所对应的超参数设置及评价指标结果,反映了模型在当前变量输入条件下的最优表现。

大多数目标变量的最优丢弃率为 0.1,这表明适当的 Dropout 机制能够有效抑制过拟合,保持模型的学习能力。当丢弃率为 0 时,模型易出现过拟合现象,表现为训练集上的 R^2 值较高,而测试集上的 R^2 值显著降低;而当丢弃率过高时,部分目标变量的 R^2 值明显下降,说明过高的丢弃率可能导致学习效果的损失。

在目标变量的超参数选择方面,高锰酸盐指数 (IMn)、氨氮 ($\text{NH}_4^+\text{-N}$) 和总氮 (TN) 的最佳隐藏层结构组合为 (256, 256, 128),而逐日平均流量 (Q) 和总磷 (TP) 的最优组合则为 (512, 512, 256)。这可能反映了不同目标变量在时间序列变化特征上的差异。例如,总磷 (TP) 具有较强的波动性和非线性特征,因而需要更深的网络结构以更好地提取长期趋势和复杂关系;而高锰酸盐指数 (IMn) 和总氮 (TN) 等指标的变化规律较为平稳,较小的隐藏层结构已足以捕捉其主要特征。

表 4.3 清水铺断面目标变量的 ANN 模型结构组合

目标变量	隐藏层	丢弃率	R^2_{Train}	R^2_{Test}	$\text{RMSE}_{\text{Train}}$	$\text{RMSE}_{\text{Test}}$	$\text{MAPE}_{\text{Train}}$	$\text{MAPE}_{\text{Test}}$
逐日平均流量	(256, 256, 128)	0.0	0.9981	0.9824	2.8270	10.6762	0.0543	0.0627
逐日平均流量	(256, 256, 128)	0.1	0.9976	0.9950	3.2383	5.6967	0.0716	0.0581
逐日平均流量	(256, 256, 128)	0.2	0.9956	0.9890	4.3448	8.4345	0.0965	0.0750
逐日平均流量	(256, 256, 128)	0.3	0.9932	0.9869	5.4038	9.2194	0.1184	0.0833
逐日平均流量	(512, 512, 256)	0.0	0.9981	0.9889	2.8925	8.4719	0.0510	0.0531
逐日平均流量	(512, 512, 256)	0.1	0.9979	0.9958	3.0224	5.1894	0.0682	0.0567
逐日平均流量	(512, 512, 256)	0.2	0.9955	0.9892	4.4144	8.3610	0.0915	0.0802
逐日平均流量	(512, 512, 256)	0.3	0.9923	0.9826	5.7520	10.6111	0.1167	0.1034
高锰酸盐指数	(256, 256, 128)	0.0	0.9980	0.9925	0.0395	0.0775	0.0229	0.0379
高锰酸盐指数	(256, 256, 128)	0.1	0.9984	0.9975	0.0348	0.0444	0.0217	0.0352
高锰酸盐指数	(256, 256, 128)	0.2	0.9967	0.9961	0.0509	0.0559	0.0310	0.0465
高锰酸盐指数	(256, 256, 128)	0.3	0.9972	0.9968	0.0467	0.0509	0.0298	0.0398
高锰酸盐指数	(512, 512, 256)	0.0	0.9967	0.9840	0.0509	0.1131	0.0273	0.0540
高锰酸盐指数	(512, 512, 256)	0.1	0.9983	0.9967	0.0366	0.0514	0.0223	0.0419
高锰酸盐指数	(512, 512, 256)	0.2	0.9969	0.9961	0.0492	0.0556	0.0306	0.0464
高锰酸盐指数	(512, 512, 256)	0.3	0.9938	0.9929	0.0697	0.0755	0.0427	0.0603
氨氮	(256, 256, 128)	0.0	0.9950	0.6821	0.0079	0.0086	0.2107	0.3467
氨氮	(256, 256, 128)	0.1	0.9813	0.7258	0.0153	0.0080	0.4144	0.4123

续表 4.3 清水铺断面目标变量的 ANN 模型结构组合 (续)

目标变量	隐藏层	丢弃率	R^2_{Train}	R^2_{Test}	$\text{RMSE}_{\text{Train}}$	$\text{RMSE}_{\text{Test}}$	$\text{MAPE}_{\text{Train}}$	$\text{MAPE}_{\text{Test}}$
氨氮	(256, 256, 128)	0.2	0.9819	0.7774	0.0150	0.0072	0.3635	0.3210
氨氮	(256, 256, 128)	0.3	0.9769	0.7687	0.0170	0.0073	0.3562	0.3058
氨氮	(512, 512, 256)	0.0	0.9950	0.7174	0.0079	0.0081	0.2432	0.3594
氨氮	(512, 512, 256)	0.1	0.9851	0.7341	0.0136	0.0078	0.2519	0.3026
氨氮	(512, 512, 256)	0.2	0.9813	0.6667	0.0152	0.0088	0.2065	0.3141
氨氮	(512, 512, 256)	0.3	0.9778	0.6665	0.0166	0.0088	0.3010	0.3529
总磷	(256, 256, 128)	0.0	0.9716	0.8444	0.0035	0.0147	0.2014	0.1823
总磷	(256, 256, 128)	0.1	0.9721	0.8380	0.0035	0.0150	0.1320	0.1721
总磷	(256, 256, 128)	0.2	0.9651	0.8378	0.0039	0.0150	0.1389	0.1663
总磷	(256, 256, 128)	0.3	0.9128	0.8471	0.0061	0.0146	0.1918	0.1833
总磷	(512, 512, 256)	0.0	0.9870	0.8496	0.0024	0.0144	0.1218	0.1450
总磷	(512, 512, 256)	0.1	0.9523	0.8508	0.0045	0.0144	0.1839	0.1779
总磷	(512, 512, 256)	0.2	0.9652	0.8388	0.0039	0.0150	0.1193	0.1570
总磷	(512, 512, 256)	0.3	0.9379	0.8693	0.0052	0.0135	0.1576	0.1504
总氮	(256, 256, 128)	0.0	0.9787	0.0059	0.1306	0.4447	0.0361	0.0918
总氮	(256, 256, 128)	0.1	0.9937	0.7494	0.0709	0.2233	0.0109	0.0362
总氮	(256, 256, 128)	0.2	0.9912	0.7205	0.0839	0.2358	0.0167	0.0395
总氮	(256, 256, 128)	0.3	0.9855	0.7209	0.1077	0.2356	0.0300	0.0345

续表 4.3 清水铺断面目标变量的 ANN 模型结构组合（续）

目标变量	隐藏层	丢弃率	R^2_{Train}	R^2_{Test}	$\text{RMSE}_{\text{Train}}$	$\text{RMSE}_{\text{Test}}$	$\text{MAPE}_{\text{Train}}$	$\text{MAPE}_{\text{Test}}$
总氮	(512, 512, 256)	0.0	0.9932	0.6256	0.0739	0.2729	0.0186	0.0509
总氮	(512, 512, 256)	0.1	0.9937	0.7507	0.0712	0.2227	0.0108	0.0361
总氮	(512, 512, 256)	0.2	0.9912	0.7453	0.0840	0.2251	0.0158	0.0326
总氮	(512, 512, 256)	0.3	0.9886	0.7500	0.0956	0.2230	0.0224	0.0318

注：逐日平均流量的预测模型中，RMSE 单位为 m^3/s ；其余目标变量（高锰酸盐指数、氨氮、总磷与总氮）的 RMSE 单位为 mg/L 。

表 4.4 清水铺断面 ANN 模型最优超参数与评价指标

目标变量	隐藏层	丢弃率	R^2_{Train}	R^2_{Test}	$\text{RMSE}_{\text{Train}}$	$\text{RMSE}_{\text{Test}}$	$\text{MAPE}_{\text{Train}}$	$\text{MAPE}_{\text{Test}}$
逐日平均流量	(512, 512, 256)	0.1	0.9979	0.9958	3.0224	5.1894	0.0682	0.0567
高锰酸盐指数	(256, 256, 128)	0.1	0.9984	0.9975	0.0348	0.0444	0.0217	0.0352
氨氮	(256, 256, 128)	0.2	0.9819	0.7774	0.0150	0.0072	0.3635	0.3210
总磷	(512, 512, 256)	0.0	0.9870	0.8496	0.0024	0.0144	0.1218	0.1450
总氮	(256, 256, 128)	0.1	0.9937	0.7494	0.0709	0.2233	0.0109	0.0362

注：逐日平均流量的预测模型中，RMSE 单位为 m^3/s ；其余目标变量（高锰酸盐指数、氨氮、总磷与总氮）的 RMSE 单位为 mg/L 。

根据表 4.4 的结果, ANN 模型在不同目标变量上的预测性能存在差异。总体来看, 模型在训练集上的表现优于测试集, 但不同目标变量的表现也有所不同。逐日平均流量 (Q) 和高锰酸盐指数 (IMn) 在训练集和测试集上的预测性能较为一致, 具有较高的 R^2 值和较低的 RMSE; 对于氨氮 ($\text{NH}_4^+\text{-N}$), 虽然训练集的 R^2 值较高, 但测试集的 R^2 值有所下降, 且 MAPE 值也显示了较大的偏差, 这表明低浓度水质指标的预测面临较高挑战。

从 R^2 值来看, 所有目标变量的 R^2 均较高, 尤其是逐日平均流量 (Q) 和高锰酸盐指数 (IMn), 其训练集和测试集的 R^2 值均超过 0.99。氨氮 ($\text{NH}_4^+\text{-N}$)、总氮 (TN) 和总磷 (TP) 的训练集和测试集 R^2 值有一定差异, 表现出一定程度的过拟合, 但 R^2 值仍较高, 表明 ANN 模型能够较好地捕捉这些变量的时间动态变化规律。相对而言, 总氮 (TN) 的测试集的 R^2 值为 0.7494, 虽然仍然较高, 但与其他目标变量相比略显逊色。

在 RMSE 方面, 仅总磷 (TP) 模型测试集的 RMSE 值 (0.0144 mg/L) 超过了其均值 (0.0331 mg/L) 的 10%, 其他目标变量的 RMSE 值均在其均值的 10% 内, 表明 ANN 模型在预测大部分目标变量上具有较高的准确性。误差主要来自于总磷浓度波动过大, 导致预测误差较高。此外, RMSE 值的稳定性也进一步验证了 ANN 在多数水质指标预测中的数值可靠性与推广潜力。

在 MAPE 方面, 氨氮 ($\text{NH}_4^+\text{-N}$) 模型训练集和测试集的 MAPE 均显示出稍高的偏差, 超过了 20%。主要原因可能是氨氮浓度较低, 且在长期内维持较低水平 (通常低于 0.1 mg/L), 这使得 ANN 在预测低浓度水质指标时遇到较大困难。这表明, ANN 在低浓度水质指标的预测上存在一定局限性, 特别是在数据波动性较小的情况下, 模型的预测性能较弱。未来可通过样本增强、误差重加权等策略提高此类模型的表现。

综上, 虽然 ANN 模型在大部分目标变量上的预测精度较高, 但在氨氮等低浓度指标的预测中, 仍然存在一定的局限性, 需要进一步优化模型结构或引入更多的辅助特征以提高预测精度。进一步引入多尺度建模策略或考虑数据的不确定性传播过程, 或许能在提升模型泛化能力的同时增强其对极端值和非平稳过程的响应能力。

图 4.1 展示了各目标变量最优 ANN 模型的预测值与实测值的拟合情况。从可视化结果来看, 预测值 (红色虚线) 与实测值 (蓝色实线) 较为吻合, 表明 ANN 能够较好地捕捉水质指标的时间动态变化趋势。

然而, 部分指标 (如总氮 TN 和总磷 TP) 在高值时的预测误差相对较大, 可能

是由于其时间序列中的波动较敏感，导致模型在极端值预测上存在一定偏差。此外，氨氮（ $\text{NH}_4^+\text{-N}$ ）在某些时段的预测波动较大，与其较高的 MAPE 值一致，说明模型在低浓度条件下的鲁棒性仍有提升空间。未来可结合物理约束机制或混合建模方法，进一步增强 ANN 对不同浓度水平下水质动态变化的表达能力。




图 4.1 清水铺断面 ANN 模型预测结果

4.3 ANN 模型可解释性分析

为探究输入特征对 ANN 模型预测结果的相对影响，本文采用第 2 章中已介绍的随机森林变量重要性评估方法，构建独立的解释模型，对已训练的 ANN 输入特征进行后验分析。通过计算基于 Gini 不纯度的特征重要性得分，并归一化处理，提取每个目标变量对应的重要性排名前三的关键变量，以揭示模型学习过程中对各类因子的敏感性和依赖度。分析结果如表 4.5 所示。

表 4.5 各目标变量对应的主要影响因子及其特征重要性排序

排名	Q		IMn		NH ₄ ⁺ -N		TP		TN	
	变量名	重要性	变量名	重要性	变量名	重要性	变量名	重要性	变量名	重要性
1	含沙量	0.5457	浊度	0.5241	TN	0.6381	TN	0.4021	TP	0.5960
2	pH	0.0730	TP	0.1497	TP	0.0919	IMn	0.3803	NH ₄ ⁺ -N	0.1412
3	日最高气温	0.0513	水温	0.1052	水温	0.0502	浊度	0.0775	浊度	0.0793

对于逐日平均流量 Q，特征重要性排名前三的变量依次为逐日平均含沙量（0.5457）、pH（0.0730）和日最高气温（0.0513）。含沙量的重要性得分显著高于其余变量，表明其在模型中的主导地位。作为流量变化的直接响应指标，含沙量反映了水文过程中的泥沙输移特征，受流速与流量共同影响，因此其重要性排名首位具备充分的水文机制支撑。pH 和气温对流量影响相对次要，可能通过调节蒸发强度、水体化学过程或藻类活动等间接作用引起变化。值得注意的是，降雨量常被认为是影响流量的重要因子，但在本研究中未进入前三，可能由于研究区域内水文响应较为平缓，或者降雨与流量间存在时间滞后效应，难以被当前模型直接捕捉。

高锰酸盐指数 IMn 的前三个重要变量依次为浊度（0.5241）、TP（0.1497）和水温（0.1052）。其中，浊度的显著影响表明水体周边地形可能对污染物输移和汇集路径具有决定性作用。TP 作为有机物与营养盐浓度的代表，其与 IMn 的显著相关性反映了水体中还原性物质的变化。水温则可能影响微生物活动与有机质分解速率，模型在有机物预测中具有良好的解释性与稳定性。

氨氮 NH₄⁺-N 的主要影响因子为 TN（0.6381）、TP（0.0919）和水温（0.0502）；TN 作为氨氮的上游来源，在氮循环中具有核心地位，其特征重要性显著高于其余变量，说明 NH₄⁺-N 浓度主要受 TN 驱动。TP 与水温则可能通过调节微生物过程、反硝化速率等间接作用于 NH₄⁺-N 的生成与转化。模型在变异源追踪方面反映了典型氮循环路径，具有较强的环境过程合理性。

总磷 TP 的重要变量为 NH₄⁺-N（0.4021）、IMn（0.3830）和水温（0.0775）。NH₄⁺-N 与 TP 同属水体营养盐，二者在污染输入、藻类吸收及水体沉积过程中存在协同关系，因此其在模型中的特征重要性基本接近。IMn 与有机物富营养相关，可能影响 TP 的生物可利用性，进而提高模型识别能力。水温的作用相对较弱，但仍可能通过调节水环境反应速率影响 TP 浓度变化。

总氮 TN 的前三个重要变量分别为 TP（0.5960）、NH₄⁺-N（0.1412）与浊度

(0.0793)。TP 与 $\text{NH}_4^+\text{-N}$ 共同构成水体营养结构要素，氮磷耦合、转换与富营养过程相关性较强，坡度对径流与营养盐运移过程的影响仍具有一定的水文学解释作用。整体来看，模型识别出的主要变量符合水体氮循环和污染输移的基本规律。

综上，特征重要性排序与已有水文与水质过程知识基础基本吻合，表明 ANN 模型在目标变量建模中具备良好的解释性与理论支撑。

4.4 ANN 模型用于河流水质预警

在完成清水铺断面的 ANN 模型预测后，结合第 2 章中设定的固定阈值法预警机制，对预测结果进行超标判定。由于流量指标无国家标准限值，故不纳入预警分析。

图 4.2 展示了高锰酸盐指数、氨氮、总磷和总氮的逐日预测值及其对应的预警判断结果。其中，黑色虚线表示各水质因子的标准限值，红色圆点代表预测值超出限值的时刻，即触发预警的日期。




图 4.2 清水铺断面 ANN 模型预警结果

从预警结果来看，清水铺断面的高锰酸盐指数和总磷偶尔超标，氨氮几乎不超标，而总氮呈现持续超标趋势，这表明流域内氮污染压力较大，可能与农业面源污染有关。此外，从季节性趋势来看，高锰酸盐指数和总磷的超标现象在夏季较为明显，这可能与降雨冲刷及流域内污染物输移过程有关。

4.5 本章小结

本章构建了基于 ANN 的河流水质时间预测与预警模型，并以清水铺断面为例，系统完成了从输入变量筛选、训练优化、结果解释到预警机制构建的完整建模流程。

研究结果表明，ANN 模型在多项水质指标的预测任务中展现出较强的拟合能力与泛化能力，尤其在逐日平均流量（Q）和高锰酸盐指数（IMn）两个指标上，模型在训练集和测试集上的决定系数 R^2 均超过 0.99，说明其对于流域水质的动态变化趋势具有良好的学习与表征能力。然而，对于氨氮等低浓度、波动性较强的目标变量，模型预测结果仍存在一定误差，提示当前模型结构在捕捉微弱变化方面仍有优化空间，未来可尝试引入更丰富的上游输入特征或改进神经网络结构以提升其敏感性与稳定性。

在模型可解释性方面，通过归一化特征重要性分析，明确了各类输入变量（如气温、水质历史值等）对目标指标的贡献程度，揭示了污染物形成与转化的内在路径，有助于流域水环境演变机制的认知与监测因子的优化选择。

同时，基于国家水质标准限值构建的固定阈值式预警机制简洁有效，能够在预测结果超过警戒线时实时触发预警，为流域水环境的智能管控与突发事件响应提供了技术支撑。整体来看，该机制具备良好的实际部署能力和后续扩展潜力。

综上，本章不仅展示了 ANN 模型在流域水质预测任务中的应用潜力，也验证了其在数据驱动的水环境智能预警体系构建中的可行性。未来研究可进一步引入 LSTM、Transformer 等更复杂的时序深度学习模型，以增强模型对非线性变化与突发污染事件的动态感知能力，提升水质预测与预警的智能化水平。

第 5 章 基于 STGCN 的流域水质时空预测模型构建与应用

在流域水环境管理中，构建融合多源数据的高精度预测模型是提升污染响应能力的关键技术环节。前期已采用 ANN 模型实现了基于时间序列的水质预测，但其未能有效利用流域内部的空间结构信息，限制了对污染物演变过程的刻画。为进一步提升模型性能，本章引入时空图卷积网络（STGCN），构建融合遥感、气象、水质及污染排放数据的时空预测模型。

STGCN 模型能够同时捕捉空间依赖关系与时间动态特征，适用于流域系统。为保证模型输入的科学性，建模前对关键输入变量进行识别，并引入污水处理厂的滞后变量，以考虑点源污染对断面水质的时滞影响。随后，评估不同的图结构与超参数配置，确定最优模型结构，并基于固定阈值构建水质预警机制。

在此基础上，本章进一步开展跨子流域迁移实验与数据缺失情境建模，系统检验 STGCN 的泛化能力与适用边界，探索其在复杂流域管理中的应用潜力。

5.1 关键输入变量识别与优化

本研究构建了融合气象、水质、遥感等多源数据的流域水质时空预测与预警模型（变量详见表 5.1）。以石坎断面为研究对象，主要由于其地理位置处于流域内部，更有助于结合空间特征。

石坎断面隶属于子流域 10，该子流域内共划分 350 个空间网格。为降低模型计算复杂度，并引入更符合水文动力过程的汇水特征，本文优先构建该子流域的局部模型。所使用数据包括：石坎断面水质监测数据、叙永站气象观测数据、子流域内每一网格七维波段数据，以及基于栅格邻接关系生成的空间图结构。模型以总磷、氨氮、总氮作为预测目标变量，所有输入特征均经标准化处理。

表 5.1 未经选择的 STGCN 模型输入变量

变量类型	变量数量	变量名称
气象变量	6	日最高气温、日最低气温、相对湿度、风速、日照时数、降水量
水质变量	3	氨氮、总磷、总氮
植被覆盖	7	波段 1~7

由于原始变量数量较多，若直接用于建模，可能引发特征冗余、模型复杂度升高及过拟合风险，不利于揭示变量与目标之间的真实关系。因此，本文采用多层次变量选择方法系统识别代表性输入变量，具体方法包括相关性分析和递归特征消除两个阶段。首先，计算各输入变量与目标变量之间的 Pearson 相关系数，筛选线性相关性较低的变量。随后，以随机森林回归器（Random Forest Regressor）为评估器，执行 RFE 方法，递归剔除冗余变量并排序剩余变量的重要性。在最终筛选阶段，综合两种排序结果及变量物理意义，确定各目标变量对应的关键输入变量集。表 5.2 汇总了每个目标变量的前 10 个关键输入变量，作为模型构建的核心特征基础。

表 5.2 STGCN 模型输入变量选择结果

目标变量	关键输入变量（按重要性排序）
氨氮 $\text{NH}_4^+\text{-N}$	氨氮、日最高气温、日最低气温、总磷、总氮、b07、b05、平均相对湿度、b03、b06、平均风速
总磷 TP	总磷、日最低气温、总氮、氨氮、日最高气温、b07、平均相对湿度、b05、b06、平均风速、b03
总氮 TN	总氮、日最低气温、总磷、日最高气温、氨氮、平均相对湿度、b07、b03、日照时数、平均风速、b05

在上述基础变量筛选的基础上，本文进一步引入外生影响因素进行变量拓展。考虑到石坎断面上游存在案例区内唯一一个大型生活污水处理厂，该污水处理厂的运行参数可能对水质变化具有重要驱动作用。因此，本文引入污水处理厂运行数据作为外生变量，以增强模型对人为污染过程的动态响应能力。该处理厂数据覆盖 2019 年 1 月 1 日至 2022 年 12 月 31 日，前三年为逐月尺度，2022 年为逐日尺度，共包含 10 项运行指标，涵盖处理规模、进出水浓度等关键变量。

为识别与目标变量关联性强的排污变量，本文设置滞后窗口为 0 至 14 天，采用 Pearson 相关系数分析其滞后相关性，记录最大相关系数及其对应的最优滞后天数。若某变量在整个滞后窗口内未表现出显著相关性，则不予纳入后续建模。表 5.3 汇总了最终保留变量的最佳滞后时间，并反映出不同污染物在时滞响应机制上的异同。

最终，本文构建“滞后变量增强特征集”，将具有显著滞后影响的变量（如“氨氮浓度_Lag2”）纳入模型输入，以更准确地刻画上游排污输入对下游水质的延迟性响应，从而提升模型在模拟突发性污染过程中的适应能力与解释性。

表 5.3 污水处理厂变量与石坎断面目标变量的最佳滞后天数

目标变量	污水处理厂变量	最佳滞后天数（天）
氨氮	氨氮浓度	2
	总氮浓度	5
	污水流量均值	5
	污水流量累计值	5
总磷	总氮浓度	1
	总氮排放量	1
	总磷浓度	1
	总磷排放量	1
	污水流量均值	2
	污水流量累计值	2
总氮	总氮浓度	3
	总氮排放量	3
	污水流量均值	2
	污水流量累计值	2

5.2 流域水质时空预测模型构建

与前文中 ANN 模型使用的 MinMaxScaler 不同，本文采用 StandardScaler 将数值特征标准化至均值为 0、标准差为 1 的分布区间，保持了输入变量的相对差异性，更适用于本研究中的图神经网络建模需求，有助于模型在不同尺度变量间保持权重平衡。

为更有效捕捉流域内部网格间的空间关联特征，模型采用图神经网络架构，构建两层图卷积结构的时空图卷积神经网络（STGCN）。该模型设计不同的基本卷积单元，结合 Dropout 机制和全连接层实现空间特征的编码与水质变量的预测。模型结构包括：第一层图卷积用于对原始输入进行特征提取，使用 ReLU 激活函数，并接入 Dropout 层以进行正则化；第二层图卷积进一步整合空间特征后，连接全连接层输出最终预测结果。在训练过程中，模型使用构建的图结构来捕捉流域网格之间的空间关系。图中节点表示 350 个网格，边的连接由边权数据决定，最终构造的 edge_index 和 edge_weight 将作为图神经网络的输入，从而充分体现子流域内部及邻近单元的交互特征。

训练过程中采用 AdamW 优化器，设置的损失函数为均方误差（MSE），以衡量模型输出与实际观测值之间的偏离程度。训练过程共进行 1000 个轮次（epoch），每轮处理的样本批量大小（batch size）为 64。模型性能评估采用决定系数（ R^2 ）、均方根误差（RMSE）、平均绝对误差（MAE）、平均绝对百分比误差（MAPE）四项指标，用以综合衡量不同超参数组合下的预测精度与稳定性。模型预测方式采用逐步递归策略：在第 t 日的训练与验证中，仅使用 $t-1$ 日及更早的数据作为输入，确保建模过程具备前瞻性与合理性。模型训练完成后，可通过滚动输入的方式，逐步扩展预测时长，实现月尺度乃至季节尺度的连续水质预测。

为评估模型结构对预测性能的影响，本文设计多组超参数组合方案，测试以下三类设置：

- （1）四种图卷积类型：TransformerConv，GCNConv，SAGEConv，GATConv；
- （2）三种隐藏层规模：64，128，256；
- （3）四种 Dropout 丢弃率：0，0.1，0.2，0.3。

通过组合实验探索最适合不同水质参数的模型配置方案，以提升预测精度与模型稳定性。其中，总氮、总磷、氨氮的 STGCN 模型结构组合及其评价指标如表 5.4 所示，最优超参数配置与评估结果汇总于表 5.5。

由表 5.5 可见，总氮、总磷和氨氮在 STGCN 模型中的预测表现均非常优异。三个目标变量的最优模型在训练集和测试集上的 R^2 值均超过 0.9，表明模型具有良好的拟合能力，且未出现明显过拟合现象。RMSE 指标同样表现出色，误差均控制在相应水质指标浓度均值的 10% 以内，进一步验证了模型的稳定性与精度。

在 MAPE 指标方面，氨氮的相对误差略高，但从 MAE 指标来看，其测试集和训练集的平均绝对误差分别为 0.0019 mg/L 和 0.0020 mg/L，均为极小值。造成 MAPE 偏大的原因在于氨氮本身的数值基准较低，因此在相对误差计算中更容易放大绝对误差的影响，属于数值尺度效应而非模型精度不足所致。综合上述结果可知，STGCN 模型不仅提升了预测性能，也在复杂地形与时空条件下展现出更强的鲁棒性。

5.3 STGCN 模型可解释性分析

与 ANN 模型的可解释性分析类似，STGCN 模型同样通过特征重要性计算方法评估各输入变量对目标变量的相对贡献。通过归一化后的特征重要性得分（见表 5.6），可揭示流域内水质演变的关键影响因子。

表 5.4 石坎断面目标变量的 STGCN 模型结构组合

目标变量	卷积类型	隐藏层	丢弃率	R^2_{Train}	R^2_{Test}	$\text{RMSE}_{\text{Train}}$	$\text{RMSE}_{\text{Test}}$	$\text{MAE}_{\text{Train}}$	MAE_{Test}	$\text{MAPE}_{\text{Train}}$	$\text{MAPE}_{\text{Test}}$
总氮	TransformerConv	64	0.0	0.9985	0.9978	0.0230	0.0298	0.0104	0.0128	0.0025	0.0032
总氮	TransformerConv	64	0.1	0.9362	0.9342	0.1520	0.1634	0.1130	0.1233	0.0280	0.0297
总氮	TransformerConv	64	0.2	0.9003	0.8866	0.1900	0.2146	0.1454	0.1562	0.0361	0.0385
总氮	TransformerConv	64	0.3	0.7634	0.7497	0.2928	0.3189	0.2272	0.2422	0.0558	0.0589
总氮	TransformerConv	128	0.0	0.9995	0.9997	0.0135	0.0103	0.0062	0.0053	0.0015	0.0013
总氮	TransformerConv	128	0.1	0.8756	0.8680	0.2123	0.2315	0.1659	0.1815	0.0407	0.0438
总氮	TransformerConv	128	0.2	0.7047	0.6771	0.3271	0.3622	0.2549	0.2792	0.0632	0.0685
总氮	TransformerConv	128	0.3	0.7116	0.7241	0.3233	0.3348	0.2430	0.2574	0.0596	0.0635
总氮	TransformerConv	256	0.0	0.7960	0.7881	0.2719	0.2934	0.2111	0.2292	0.0523	0.0566
总氮	TransformerConv	256	0.1	0.7737	0.7685	0.2864	0.3066	0.2160	0.2314	0.0529	0.0564
总氮	TransformerConv	256	0.2	0.8223	0.7965	0.2538	0.2875	0.1929	0.2194	0.0476	0.0539
总氮	TransformerConv	256	0.3	0.7603	0.7684	0.2947	0.3067	0.2217	0.2347	0.0542	0.0577
总氮	GCNConv	64	0.0	0.9582	0.9592	0.1230	0.1287	0.0876	0.0897	0.0216	0.0220
总氮	GCNConv	64	0.1	0.8651	0.8499	0.2211	0.2469	0.1645	0.1909	0.0407	0.0471
总氮	GCNConv	64	0.2	0.8523	0.8390	0.2313	0.2558	0.1744	0.1964	0.0430	0.0486
总氮	GCNConv	64	0.3	0.7381	0.7172	0.3080	0.3389	0.2380	0.2619	0.0588	0.0649
总氮	GCNConv	128	0.0	0.9931	0.9918	0.0499	0.0578	0.0301	0.0343	0.0075	0.0085
总氮	GCNConv	128	0.1	0.9569	0.9512	0.1250	0.1407	0.0922	0.1017	0.0228	0.0248

续表 5.4 石坎断面目标变量的 STGCN 模型结构组合 (续)

目标变量	卷积类型	隐藏层	丢弃率	R^2_{Train}	R^2_{Test}	$\text{RMSE}_{\text{Train}}$	$\text{RMSE}_{\text{Test}}$	$\text{MAE}_{\text{Train}}$	MAE_{Test}	$\text{MAPE}_{\text{Train}}$	$\text{MAPE}_{\text{Test}}$
总氮	GCNConv	128	0.2	0.9124	0.9040	0.1782	0.1975	0.1304	0.1504	0.0323	0.0371
总氮	GCNConv	128	0.3	0.7629	0.7516	0.2931	0.3176	0.2250	0.2420	0.0556	0.0600
总氮	GCNConv	256	0.0	0.9991	0.9989	0.0177	0.0207	0.0077	0.0078	0.0020	0.0019
总氮	GCNConv	256	0.1	0.9697	0.9690	0.1048	0.1122	0.0725	0.0807	0.0180	0.0200
总氮	GCNConv	256	0.2	0.9599	0.9589	0.1205	0.1292	0.0889	0.0949	0.0220	0.0232
总氮	GCNConv	256	0.3	0.9541	0.9543	0.1290	0.1362	0.0942	0.1004	0.0232	0.0246
总氮	SAGEConv	64	0.0	0.9957	0.9956	0.0395	0.0424	0.0226	0.0248	0.0056	0.0061
总氮	SAGEConv	64	0.1	0.9254	0.9185	0.1645	0.1820	0.1199	0.1367	0.0292	0.0333
总氮	SAGEConv	64	0.2	0.7414	0.7298	0.3061	0.3313	0.2372	0.2582	0.0581	0.0632
总氮	SAGEConv	64	0.3	0.7962	0.7744	0.2717	0.3027	0.2087	0.2344	0.0516	0.0578
总氮	SAGEConv	128	0.0	0.9991	0.9994	0.0176	0.0152	0.0071	0.0072	0.0018	0.0018
总氮	SAGEConv	128	0.1	0.9344	0.9277	0.1542	0.1714	0.1153	0.1302	0.0286	0.0323
总氮	SAGEConv	128	0.2	0.8983	0.8908	0.1920	0.2106	0.1460	0.1627	0.0361	0.0401
总氮	SAGEConv	128	0.3	0.8489	0.8291	0.2340	0.2635	0.1773	0.1999	0.0437	0.0492
总氮	SAGEConv	256	0.0	0.9999	0.9999	0.0073	0.0063	0.0029	0.0028	0.0007	0.0007
总氮	SAGEConv	256	0.1	0.9225	0.9172	0.1676	0.1834	0.1221	0.1365	0.0301	0.0335
总氮	SAGEConv	256	0.2	0.8542	0.8418	0.2299	0.2535	0.1727	0.1924	0.0425	0.0473
总氮	SAGEConv	256	0.3	0.7772	0.7751	0.2841	0.3022	0.2162	0.2340	0.0530	0.0575

续表 5.4 石坎断面目标变量的 STGCN 模型结构组合 (续)

目标变量	卷积类型	隐藏层	丢弃率	R^2_{Train}	R^2_{Test}	$\text{RMSE}_{\text{Train}}$	$\text{RMSE}_{\text{Test}}$	$\text{MAE}_{\text{Train}}$	MAE_{Test}	$\text{MAPE}_{\text{Train}}$	$\text{MAPE}_{\text{Test}}$
总氮	GATConv	64	0.0	0.9217	0.8971	0.1684	0.2045	0.1221	0.1458	0.0298	0.0356
总氮	GATConv	64	0.1	0.9009	0.8900	0.1895	0.2114	0.1397	0.1580	0.0345	0.0385
总氮	GATConv	64	0.2	0.8323	0.8093	0.2465	0.2783	0.1868	0.2181	0.0461	0.0539
总氮	GATConv	64	0.3	0.8282	0.8126	0.2495	0.2759	0.1927	0.2160	0.0477	0.0532
总氮	GATConv	128	0.0	0.9895	0.9909	0.0616	0.0608	0.0395	0.0397	0.0098	0.0099
总氮	GATConv	128	0.1	0.9505	0.9386	0.1339	0.1580	0.0947	0.1149	0.0233	0.0279
总氮	GATConv	128	0.2	0.9412	0.9392	0.1459	0.1571	0.1069	0.1167	0.0265	0.0288
总氮	GATConv	128	0.3	0.8756	0.8598	0.2124	0.2387	0.1597	0.1825	0.0397	0.0446
总氮	GATConv	256	0.0	0.9988	0.9990	0.0205	0.0204	0.0091	0.0100	0.0022	0.0025
总氮	GATConv	256	0.1	0.9920	0.9901	0.0538	0.0635	0.0365	0.0404	0.0090	0.0098
总氮	GATConv	256	0.2	0.9856	0.9838	0.0723	0.0812	0.0510	0.0577	0.0126	0.0140
总氮	GATConv	256	0.3	0.9866	0.9860	0.0696	0.0754	0.0510	0.0548	0.0127	0.0135
总磷	TransformerConv	64	0.0	0.9950	0.9936	0.0043	0.0047	0.0021	0.0024	0.0115	0.0123
总磷	TransformerConv	64	0.1	0.9014	0.8993	0.0191	0.0188	0.0143	0.0143	0.0793	0.0764
总磷	TransformerConv	64	0.2	0.9190	0.9166	0.0173	0.0171	0.0132	0.0133	0.0746	0.0741
总磷	TransformerConv	64	0.3	0.7716	0.7793	0.0291	0.0278	0.0220	0.0218	0.1233	0.1158
总磷	TransformerConv	128	0.0	0.9976	0.9971	0.0030	0.0032	0.0018	0.0020	0.0106	0.0110
总磷	TransformerConv	128	0.1	0.9323	0.9258	0.0158	0.0161	0.0115	0.0122	0.0632	0.0652

续表 5.4 石坎断面目标变量的 STGCN 模型结构组合（续）

目标变量	卷积类型	隐藏层	丢弃率	R^2_{Train}	R^2_{Test}	$\text{RMSE}_{\text{Train}}$	$\text{RMSE}_{\text{Test}}$	$\text{MAE}_{\text{Train}}$	MAE_{Test}	$\text{MAPE}_{\text{Train}}$	$\text{MAPE}_{\text{Test}}$
总磷	TransformerConv	128	0.2	0.9407	0.9378	0.0148	0.0148	0.0109	0.0112	0.0611	0.0614
总磷	TransformerConv	128	0.3	0.8183	0.8219	0.0259	0.0250	0.0198	0.0195	0.1105	0.1056
总磷	TransformerConv	256	0.0	0.9951	0.9950	0.0043	0.0042	0.0025	0.0026	0.0142	0.0142
总磷	TransformerConv	256	0.1	0.9545	0.9511	0.0130	0.0131	0.0092	0.0095	0.0507	0.0508
总磷	TransformerConv	256	0.2	0.8519	0.8515	0.0234	0.0228	0.0177	0.0176	0.0982	0.0935
总磷	TransformerConv	256	0.3	0.8272	0.8370	0.0253	0.0239	0.0193	0.0185	0.1078	0.0996
总磷	GCNConv	64	0.0	0.9356	0.9326	0.0154	0.0154	0.0112	0.0113	0.0622	0.0593
总磷	GCNConv	64	0.1	0.8600	0.8727	0.0227	0.0211	0.0166	0.0161	0.0924	0.0851
总磷	GCNConv	64	0.2	0.8231	0.8306	0.0256	0.0244	0.0191	0.0188	0.1085	0.1001
总磷	GCNConv	64	0.3	0.7914	0.8041	0.0278	0.0262	0.0206	0.0201	0.1131	0.1050
总磷	GCNConv	128	0.0	0.9939	0.9949	0.0048	0.0043	0.0027	0.0025	0.0158	0.0140
总磷	GCNConv	128	0.1	0.9280	0.9327	0.0163	0.0154	0.0116	0.0111	0.0645	0.0602
总磷	GCNConv	128	0.2	0.8605	0.8632	0.0227	0.0219	0.0169	0.0168	0.0933	0.0876
总磷	GCNConv	128	0.3	0.8767	0.8845	0.0213	0.0201	0.0158	0.0154	0.0876	0.0806
总磷	GCNConv	256	0.0	0.9968	0.9977	0.0034	0.0029	0.0014	0.0012	0.0086	0.0068
总磷	GCNConv	256	0.1	0.9833	0.9849	0.0078	0.0073	0.0050	0.0050	0.0281	0.0269
总磷	GCNConv	256	0.2	0.9348	0.9387	0.0155	0.0147	0.0113	0.0105	0.0625	0.0555
总磷	GCNConv	256	0.3	0.9261	0.9371	0.0165	0.0149	0.0121	0.0110	0.0656	0.0581

续表 5.4 石坎断面目标变量的 STGCN 模型结构组合 (续)

目标变量	卷积类型	隐藏层	丢弃率	R^2_{Train}	R^2_{Test}	$\text{RMSE}_{\text{Train}}$	$\text{RMSE}_{\text{Test}}$	$\text{MAE}_{\text{Train}}$	MAE_{Test}	$\text{MAPE}_{\text{Train}}$	$\text{MAPE}_{\text{Test}}$
总磷	SAGEConv	64	0.0	0.9897	0.9872	0.0062	0.0067	0.0031	0.0037	0.0179	0.0220
总磷	SAGEConv	64	0.1	0.9202	0.9216	0.0172	0.0166	0.0125	0.0128	0.0685	0.0685
总磷	SAGEConv	64	0.2	0.8929	0.8932	0.0199	0.0194	0.0148	0.0147	0.0848	0.0793
总磷	SAGEConv	64	0.3	0.8274	0.8303	0.0253	0.0244	0.0190	0.0188	0.1043	0.0989
总磷	SAGEConv	128	0.0	0.9989	0.9990	0.0020	0.0019	0.0007	0.0009	0.0044	0.0051
总磷	SAGEConv	128	0.1	0.9716	0.9749	0.0102	0.0094	0.0068	0.0064	0.0382	0.0355
总磷	SAGEConv	128	0.2	0.9472	0.9442	0.0140	0.0140	0.0099	0.0103	0.0539	0.0549
总磷	SAGEConv	128	0.3	0.8680	0.8598	0.0221	0.0222	0.0165	0.0172	0.0908	0.0907
总磷	SAGEConv	256	0.0	0.9997	0.9990	0.0011	0.0018	0.0002	0.0003	0.0012	0.0018
总磷	SAGEConv	256	0.1	0.9650	0.9664	0.0114	0.0109	0.0077	0.0080	0.0427	0.0436
总磷	SAGEConv	256	0.2	0.8930	0.8997	0.0199	0.0188	0.0146	0.0143	0.0812	0.0760
总磷	SAGEConv	256	0.3	0.8954	0.8929	0.0197	0.0194	0.0144	0.0149	0.0810	0.0796
总磷	GATConv	64	0.0	0.9723	0.9751	0.0101	0.0094	0.0069	0.0066	0.0377	0.0346
总磷	GATConv	64	0.1	0.8812	0.8859	0.0210	0.0200	0.0159	0.0152	0.0882	0.0815
总磷	GATConv	64	0.2	0.8467	0.8491	0.0238	0.0230	0.0178	0.0172	0.1020	0.0955
总磷	GATConv	64	0.3	0.8169	0.8219	0.0260	0.0250	0.0201	0.0197	0.1146	0.1063
总磷	GATConv	128	0.0	0.9926	0.9949	0.0052	0.0042	0.0028	0.0024	0.0153	0.0130
总磷	GATConv	128	0.1	0.9464	0.9527	0.0141	0.0129	0.0099	0.0095	0.0542	0.0495

续表 5.4 石坎断面目标变量的 STGCN 模型结构组合 (续)

目标变量	卷积类型	隐藏层	丢弃率	R^2_{Train}	R^2_{Test}	$\text{RMSE}_{\text{Train}}$	$\text{RMSE}_{\text{Test}}$	$\text{MAE}_{\text{Train}}$	MAE_{Test}	$\text{MAPE}_{\text{Train}}$	$\text{MAPE}_{\text{Test}}$
总磷	GATConv	128	0.2	0.9091	0.9225	0.0183	0.0165	0.0135	0.0125	0.0743	0.0656
总磷	GATConv	128	0.3	0.8943	0.9071	0.0198	0.0181	0.0146	0.0139	0.0812	0.0737
总磷	GATConv	256	0.0	0.9960	0.9986	0.0038	0.0022	0.0014	0.0010	0.0084	0.0056
总磷	GATConv	256	0.1	0.9871	0.9889	0.0069	0.0062	0.0043	0.0040	0.0235	0.0218
总磷	GATConv	256	0.2	0.9816	0.9862	0.0083	0.0070	0.0054	0.0048	0.0296	0.0257
总磷	GATConv	256	0.3	0.9737	0.9792	0.0099	0.0085	0.0067	0.0061	0.0367	0.0327
氨氮	TransformerConv	64	0.0	0.9991	0.9985	0.0040	0.0046	0.0019	0.0020	0.3894	0.1792
氨氮	TransformerConv	64	0.1	0.8189	0.7736	0.0551	0.0572	0.0396	0.0397	9.2121	7.3195
氨氮	TransformerConv	64	0.2	0.8510	0.7989	0.0499	0.0539	0.0364	0.0400	8.3104	6.4362
氨氮	TransformerConv	64	0.3	0.6842	0.6021	0.0727	0.0758	0.0526	0.0549	12.1230	8.6131
氨氮	TransformerConv	128	0.0	0.9986	0.9990	0.0048	0.0039	0.0014	0.0013	0.2032	0.0816
氨氮	TransformerConv	128	0.1	0.8354	0.7823	0.0525	0.0561	0.0357	0.0387	8.5726	5.1966
氨氮	TransformerConv	128	0.2	0.8402	0.8057	0.0517	0.0530	0.0367	0.0374	8.6284	5.4231
氨氮	TransformerConv	128	0.3	0.6173	0.5520	0.0800	0.0804	0.0561	0.0575	11.4288	7.8655
氨氮	TransformerConv	256	0.0	0.8219	0.7995	0.0546	0.0538	0.0363	0.0349	7.0905	4.0515
氨氮	TransformerConv	256	0.1	0.8210	0.7721	0.0547	0.0574	0.0382	0.0396	8.5665	6.1595
氨氮	TransformerConv	256	0.2	0.6466	0.5964	0.0769	0.0763	0.0541	0.0539	11.6753	8.7260
氨氮	TransformerConv	256	0.3	0.7280	0.6321	0.0675	0.0729	0.0479	0.0507	10.2427	8.3460

续表 5.4 石坎断面目标变量的 STGCN 模型结构组合 (续)

目标变量	卷积类型	隐藏层	丢弃率	R^2_{Train}	R^2_{Test}	$\text{RMSE}_{\text{Train}}$	$\text{RMSE}_{\text{Test}}$	$\text{MAE}_{\text{Train}}$	MAE_{Test}	$\text{MAPE}_{\text{Train}}$	$\text{MAPE}_{\text{Test}}$
氨氮	GCNConv	64	0.0	0.9392	0.9155	0.0319	0.0349	0.0215	0.0238	5.0181	5.8606
氨氮	GCNConv	64	0.1	0.8082	0.7535	0.0567	0.0597	0.0408	0.0429	10.0206	7.6767
氨氮	GCNConv	64	0.2	0.7274	0.6372	0.0675	0.0724	0.0490	0.0519	11.6909	8.6226
氨氮	GCNConv	64	0.3	0.7734	0.6876	0.0616	0.0672	0.0450	0.0490	10.9286	8.1241
氨氮	GCNConv	128	0.0	0.9850	0.9789	0.0159	0.0174	0.0091	0.0096	2.3747	2.6420
氨氮	GCNConv	128	0.1	0.8709	0.8071	0.0465	0.0528	0.0333	0.0368	7.9271	6.1537
氨氮	GCNConv	128	0.2	0.7921	0.7346	0.0590	0.0619	0.0413	0.0439	9.6448	7.0897
氨氮	GCNConv	128	0.3	0.7466	0.6803	0.0651	0.0679	0.0463	0.0486	11.1866	7.9228
氨氮	GCNConv	256	0.0	0.9931	0.9856	0.0107	0.0144	0.0045	0.0058	1.1485	1.2416
氨氮	GCNConv	256	0.1	0.9001	0.8497	0.0409	0.0466	0.0275	0.0315	7.0154	4.9929
氨氮	GCNConv	256	0.2	0.8278	0.7772	0.0537	0.0567	0.0357	0.0381	8.0817	4.7665
氨氮	GCNConv	256	0.3	0.7967	0.7321	0.0583	0.0622	0.0396	0.0438	8.4873	6.3433
氨氮	SAGEConv	64	0.0	0.9944	0.9928	0.0097	0.0102	0.0056	0.0059	1.1855	0.6885
氨氮	SAGEConv	64	0.1	0.7631	0.7233	0.0630	0.0632	0.0436	0.0435	9.4132	5.9668
氨氮	SAGEConv	64	0.2	0.7393	0.6876	0.0661	0.0672	0.0478	0.0488	10.8514	7.6382
氨氮	SAGEConv	64	0.3	0.6685	0.6270	0.0745	0.0734	0.0531	0.0518	11.6362	9.1017
氨氮	SAGEConv	128	0.0	0.9987	0.9993	0.0047	0.0031	0.0015	0.0013	0.1787	0.0654
氨氮	SAGEConv	128	0.1	0.9180	0.8821	0.0371	0.0413	0.0248	0.0266	5.9094	3.0031

续表 5.4 石坎断面目标变量的 STGCN 模型结构组合 (续)

目标变量	卷积类型	隐藏层	丢弃率	R^2_{Train}	R^2_{Test}	$\text{RMSE}_{\text{Train}}$	$\text{RMSE}_{\text{Test}}$	$\text{MAE}_{\text{Train}}$	MAE_{Test}	$\text{MAPE}_{\text{Train}}$	$\text{MAPE}_{\text{Test}}$
氨氮	SAGEConv	128	0.2	0.7481	0.7024	0.0649	0.0656	0.0442	0.0441	10.1053	6.4402
氨氮	SAGEConv	128	0.3	0.7601	0.7309	0.0634	0.0623	0.0440	0.0444	9.7175	7.3238
氨氮	SAGEConv	256	0.0	0.9973	0.9979	0.0067	0.0055	0.0021	0.0020	0.2272	0.2038
氨氮	SAGEConv	256	0.1	0.8518	0.8225	0.0498	0.0506	0.0316	0.0314	7.1374	4.2111
氨氮	SAGEConv	256	0.2	0.7832	0.7303	0.0602	0.0624	0.0396	0.0420	8.4011	5.5667
氨氮	SAGEConv	256	0.3	0.7157	0.6713	0.0690	0.0689	0.0470	0.0476	10.1382	6.7244
氨氮	GATConv	64	0.0	0.8828	0.8520	0.0443	0.0462	0.0298	0.0320	7.3922	5.1158
氨氮	GATConv	64	0.1	0.7813	0.6764	0.0605	0.0684	0.0431	0.0481	10.7270	7.2312
氨氮	GATConv	64	0.2	0.8255	0.7828	0.0540	0.0560	0.0396	0.0407	9.4104	6.7966
氨氮	GATConv	64	0.3	0.7604	0.6846	0.0633	0.0675	0.0458	0.0484	11.1621	7.8527
氨氮	GATConv	128	0.0	0.9923	0.9892	0.0113	0.0125	0.0059	0.0065	1.5081	1.0544
氨氮	GATConv	128	0.1	0.9354	0.8909	0.0329	0.0397	0.0231	0.0272	5.8933	5.3047
氨氮	GATConv	128	0.2	0.9096	0.8569	0.0389	0.0455	0.0276	0.0324	6.9179	4.9701
氨氮	GATConv	128	0.3	0.8942	0.8504	0.0421	0.0465	0.0302	0.0336	7.9154	5.4952
氨氮	GATConv	256	0.0	0.9948	0.9909	0.0093	0.0115	0.0038	0.0044	0.9287	0.9201
氨氮	GATConv	256	0.1	0.9774	0.9673	0.0194	0.0217	0.0128	0.0140	3.1847	2.4026
氨氮	GATConv	256	0.2	0.9774	0.9632	0.0194	0.0231	0.0130	0.0144	3.6684	2.5900
氨氮	GATConv	256	0.3	0.9494	0.9301	0.0291	0.0318	0.0198	0.0216	5.4870	3.1203

表 5.5 石坎断面 STGCN 模型最优超参数与评价指标

目标变量	卷积类型	隐藏层	丢弃率	R^2_{Train}	R^2_{Test}	$RMSE_{Train}$	$RMSE_{Test}$	MAE_{Train}	MAE_{Test}	$MAPE_{Train}$	$MAPE_{Test}$
总氮	SAGEConv	256	0.0	0.9999	0.9999	0.0073	0.0063	0.0029	0.0028	0.0007	0.0007
总磷	SAGEConv	256	0.0	0.9997	0.9990	0.0011	0.0018	0.0002	0.0003	0.0012	0.0018
氨氮	TransformerConv	64	0.0	0.9991	0.9985	0.0040	0.0046	0.0019	0.0020	0.3894	0.1792

注：表中 RMSE 与 MAE 的单位均为 mg/L。

表 5.6 各目标变量对应的主要影响因子及其特征重要性排序

排名	氨氮 NH_4^+-N	重要性	总磷 TP	重要性	总氮 TN	重要性
1	日最高气温	0.1725	日最低气温	0.2840	日最低气温	0.2989
2	总磷	0.1692	总氮	0.1968	总磷	0.1805
3	日最低气温	0.1603	氨氮	0.1341	氨氮	0.1304
4	总氮	0.0999	平均风速	0.0915	平均相对湿度	0.0775
5	平均相对湿度	0.0603	日最高气温	0.0457	日最高气温	0.0651
6	平均风速	0.0597	平均相对湿度	0.0368	平均风速	0.0639
7	降水量	0.0437	b07	0.0344	b07	0.0316
8	b05	0.0437	b05	0.0286	降水量	0.0301
9	b07	0.0389	b02	0.0252	b05	0.0226
10	b06	0.0353	降水量	0.0249	b06	0.0210

在氨氮的预测中，日最高气温（0.1725）为最重要变量，其次是总磷（0.1692）和日最低气温（0.1603），这说明温度对氨氮的生成、转化及挥发过程具有显著调控作用。高温可加快微生物氨化作用和氨的挥发，低温则可能通过影响磷的沉积和再悬浮间接影响氨氮浓度。此外，总磷作为营养盐，也可能参与了氮循环中的关键过程。

在总磷模型中，日最低气温（0.2840）为最主要变量，表明低温对磷的沉积、释放及其在水体中的生物可利用性有重要影响。总氮（0.1968）和氨氮（0.1341）作为水体中常见的营养盐，也与磷存在明显的协同与互作过程，三者常共同参与富营养化进程。

对于总氮，最重要的变量是日最低气温（0.2989），其次为总磷（0.1805）和氨氮（0.1304）。低温可能抑制水体中氮类物质的转化效率，导致总氮累积，尤其在冬季表现更为明显。同时，总磷与氨氮作为氮源或伴生物，在富营养化链条中密切关联，是影响总氮浓度变化的重要背景因子。

从整体特征重要性分布看，气温因素在三项指标中均表现突出，说明温度是调控营养盐动态变化的关键外生驱动因素。营养盐之间的交互作用也得到了模型结果的印证，体现了氮磷协同控制在流域水质管理中的必要性。

值得注意的是，b05 和 b07 两个遥感波段在三个目标变量模型的影响因子排序中反复出现于前十名，显示出一定的信息贡献。其中，b05 波段（波长约为 1.55–1.75 μm ）位于短波红外区域，对地表水分、土壤湿度及裸地暴露等状态变化高度敏感，常用于监测土壤干湿状态和地表扰动特征。b07 波段（波长约为 2.08–2.35 μm ）则能更显著反映植被含水量、冠层结构及其变化，广泛用于识别植被覆盖度的动态演变与退化过程。这表明区域内的植被覆盖动态及其引发的地表特征变化，可能是影响水质的重要因素之一。

此外，降水量在三个模型中的重要性排名普遍靠后，可能与其对水质的间接影响方式有关。降水往往通过改变水流过程、温度条件及营养盐浓度产生影响，且这种影响具有一定的时滞性与非线性特征。受限于模型结构和时序粒度，其作用可能未能被充分识别，从而在特征排序中表现不突出。

结合上述分析结果以及《赤水河流域生态环境保护与治理规划（2018–2030 年）》提出的保护目标，建议从以下几个方面加强流域治理：

（1）基于温度调控机制，强化生态调蓄能力建设：考虑到温度对氨氮和总氮具有关键影响，应在上游与污染集中区域推广植被缓冲带和生态滞留带建设，提升流域天然控温与水质自净能力，减缓极端温度对污染物浓度的影响。

(2) 聚焦氮磷协同治理，提升面源污染削减效率：模型识别显示氮磷间具有高度耦合性，建议实施协同减排策略：一方面，强化化肥减量与农业排水管理；另一方面，重点控制雨季径流中氮磷的同步输入，降低富营养化风险。

(3) 推进流域分区管控与分级治理模式：依据模型揭示的影响因子差异性与目标变量的空间差异，应在流域范围内实施分区治理策略。例如，将温度波动较大或总氮敏感区域划为重点管控单元，制定差异化减排目标与工程措施，提高治理资源配置效率。

(4) 加强多地协同，提升流域整体联动治理效能：尽管区域协同并非模型直接输出，但从温度、水质变化对上下游共同影响角度出发，可推动昭通市内部及与赤水市等下游地区的联动机制建设，协同控制营养盐输入与时空分布，增强整体治理合力。

5.4 STGCN 模型用于流域水质预警

基于《地表水环境质量标准》(GB 3838-2002) II 类限值，本研究在各目标变量的最优 STGCN 模型中引入固定阈值，构建流域水质的预测预警机制。图 5.1 展示了氨氮 (NH_4^+-N)、总磷 (TP) 和总氮 (TN) 三个指标的模型预测值与实际观测值的对比结果，其中黑色虚线为标准限值，红色圆点标记预测结果超过标准限值的时刻。

总体来看，STGCN 模型能够较好地刻画水质指标的变化趋势，预测值与实际观测值拟合度较高，与前述 R^2 评估结果一致。不同目标变量的超标情况存在显著差异，反映出各水质因子在流域环境演变中所受调控机制的不同。

氨氮模型表现出较高的稳定性与预测精度，几乎无超标现象。预测结果显示，氨氮浓度始终低于 II 类标准限值，说明本流域氮源输入控制效果良好。同时，气象与水文条件对氨氮的调节作用显著，有效抑制了污染物积累，整体氨氮污染水平较低。

总磷模型在监测期内出现了少量集中性超标事件，超标持续时间较短、幅度较小。这种短期波动可能与水动力扰动、温度变化引起的底泥磷释放有关。但整体趋势相对平稳，表明流域内磷负荷较为可控，水体中总磷浓度波动处于可接受范围。

相比之下，总氮模型呈现出明显的持续性超标特征，预测浓度频繁超过 II 类标准，且远高于限值水平。该结果说明，尽管部分氮素形态（如氨氮）已得到有效

控制，但作为综合性指标的总氮仍受到较广泛的氮源累积影响。同时，氮素转化效率的降低亦可能导致其在水体中长期富集，反映出流域总氮污染治理压力依然较大。




图 5.1 石坎断面 STGCN 模型预测预警结果

5.5 STGCN 模型在不同子流域的迁移应用

在完成子流域 10 的 STGCN 模型构建后，进一步评估其在全流域范围内的迁移能力具有重要意义。若该模型能够成功应用于其他子流域并保持良好的预测效果，便有望实现对整个流域主要水质断面的预测与预警，从而提升模型的实用性和推广价值。

清水铺断面因具备相对完整的水质与气象观测数据，为模型迁移性能的验证提供了理想条件。该断面位于子流域 14，区域内共划分为 286 个网格。本研究选取子流域 14 作为迁移实验对象，将子流域 10 中 STGCN 模型学习到的目标变量与输入特征之间的关系迁移至该区域进行测试。

以总氮浓度预测为例，子流域 10 中的模型已建立起总氮与一系列输入特征之间的映射关系，包括：日最低气温（℃）、总磷（mg/L）、日最高气温（℃）、氨氮（mg/L）、平均相对湿度（%）、b07、b03、日照时数（h）、平均风速（m/s）及

b05 波段。在迁移应用过程中，模型结构与训练参数保持不变，仅将输入数据替换为子流域 14 在相应时间与空间尺度下的对应特征变量，进而通过模型输出清水铺断面的总氮浓度预测值。

随后，将模型预测结果与清水铺断面实际监测数据进行比对。若预测值与实测值之间误差较小，表明模型具备良好的区域泛化能力，能够在不同子流域间有效迁移并保持预测精度。

表 5.7 汇总了清水铺断面 STGCN 模型在三个目标变量上的最优超参数配置与性能指标。从结果来看，三个模型的表现均非常优秀。测试集 R^2 均超过 0.9，表明模型拟合效果显著；RMSE 值均低于对应指标均值的 10%，进一步验证了模型的稳定性与精度。虽然氨氮模型在训练集上的 MAPE 略高，但其 MAE 值极小（训练集为 0.0005 mg/L，测试集为 0.0011 mg/L），说明其绝对误差水平极低，MAPE 较大的主要原因在于氨氮浓度本身数值较小，属于比例误差计算中常见的波动放大现象。

表 5.7 清水铺断面 STGCN 模型最优超参数与评价指标

目标变量	总氮	总磷	氨氮
卷积类型	SAGEConv	SAGEConv	TransformerConv
隐藏层	256	256	64
丢弃率	0	0	0
R^2_{Train}	1.0000	1.0000	1.0000
R^2_{Test}	0.9348	0.9899	0.9917
$\text{RMSE}_{\text{Train}}$	0.0045	0.0001	0.0006
$\text{RMSE}_{\text{Test}}$	0.1218	0.0054	0.0014
$\text{MAPE}_{\text{Train}}$	0.0010	0.0049	28.4184
$\text{MAPE}_{\text{Test}}$	0.0179	0.0473	0.0897

注：表中 RMSE 的单位为 mg/L。

图 5.2 展示了清水铺断面 STGCN 模型的预测预警可视化结果，整体趋势与 ANN 模型结果一致。具体而言，总磷在部分时段出现轻微超标，氨氮几乎始终维持在标准限值以下，而总氮则呈现出持续性超标的态势，提示相关区域需强化长期氮污染防治措施。

综上所述，由子流域 10 构建的 STGCN 模型成功迁移至数据完整的子流域 14。这验证了模型结构本身的区域泛化能力，也与流域内土地利用类型相对单一、以耕地与林地为主的特征有关。这一结果为 STGCN 模型在全流域范围内的结构迁




图 5.2 清水铺断面 STGCN 模型预测预警结果

移与推广应用提供了实证依据。后续章节将进一步探讨该结构在水质监测数据缺失区域的适用性，以评估其在更复杂场景下的应用潜力。

5.6 STGCN 模型在缺乏水质观测数据的流域中的迁移应用

在整个赤水河流域中，仅清水铺断面与石坎断面具备逐日精度的水质观测数据，其余关键监测断面因数据粒度有限，无法满足逐日尺度的预警需求，造成水质预测在部分区域出现空白，限制了预警系统的覆盖范围与时效性。若要对流域范围内所有重点区域的高精度水质预测，至少应满足逐日尺度的时序分辨率，这对模型的适应能力与数据来源提出了更高要求。

相较于水质监测数据的稀缺性，气象站点在流域内分布较为密集，能够提供高时空分辨率的连续观测数据。同时，遥感产品可实现逐日获取，空间覆盖全面，具备作为替代输入的潜力。因此，本节尝试在缺乏水质类变量的情形下，构建依托气象与遥感数据的 STGCN 水质预测模型，以检验其在无水质观测条件下的泛化适应能力。

选取石坎断面所在的子流域 10 作为实验区域，剔除水质变量，仅保留气象因素与遥感波段数据，同时引入具有时间滞后效应的污水处理厂排放数据，并对变

量集重新进行了特征筛选。最终确定的模型输入变量如表 5.8 所示。

表 5.8 STGCN 模型输入变量选择结果

目标变量	输入变量
氨氮 $\text{NH}_4^+\text{-N}$	日最高气温、日最低气温、平均风速、平均相对湿度、b07、b05、b06、20-20 时累计降水量、b03、b02、氨氮浓度 _Lag2 、总氮浓度 _Lag5 、污水流量均值 _Lag5 、污水流量累计值 _Lag5
总磷 TP	日最低气温、平均风速、日最高气温、平均相对湿度、b07、b06、b05、20-20 时累计降水量、b03、日照时数、总氮浓度 _Lag1 、总氮排放量 _Lag1 、总磷浓度 _Lag1 、总磷排放量 _Lag1 、污水流量均值 _Lag2 、污水流量累计值 _Lag2
总氮 TN	日最低气温、平均相对湿度、平均风速、日最高气温、b07、b06、20-20 时累计降水量、b03、b05、日照时数、总氮浓度 _Lag3 、总氮排放量 _Lag3 、污水流量均值 _Lag2 、污水流量累计值 _Lag2

模型结构与超参数配置沿用前述章节中的设计框架。模型训练完成后，分别获得氨氮、总磷与总氮在不同 STGCN 结构组合下的预测性能，具体结果详见表 5.9。每一目标变量的最优结构及其对应的性能指标汇总见表 5.10。

在完全不依赖历史水质观测数据的前提下，本研究构建的 STGCN 模型依然展现出极高的预测精度。所有目标变量在测试集上的决定系数 R^2 均超过 0.99，均方根误差（RMSE）控制在各指标均值的 10% 以内，平均绝对百分比误差（MAPE）均低于 20%。同时，训练集与测试集之间的误差指标接近，表明模型拟合效果稳定，未出现明显过拟合，具备良好的泛化能力。

本节结果表明，即便在完全缺乏历史水质观测数据的条件下，STGCN 模型仍可依托气象与遥感等高时空分辨率数据构建，并实现对目标水质变量的有效预测，展现出在数据受限环境下的建模能力与应用潜力。

结合第 5.5 节子流域间结构迁移实验的结果，可进一步推断：该模型结构不仅在观测数据完整的区域表现稳定，也具备迁移至水质数据不完善区域的可行性。即使目标子流域的数据质量一般，模型仍可能借助辅助变量实现高质量的迁移应用与预警响应，体现出较强的泛化能力与实用价值。

综上，STGCN 模型在结构可迁移性与输入灵活性方面均具备优势，未来可进一步探索其在跨流域迁移、水质长期预测及多源数据融合预警系统中的推广与深化应用。

表 5.9 石坎断面目标变量的 STGCN 模型结构组合

目标变量	卷积类型	隐藏层	丢弃率	R^2_{Train}	R^2_{Test}	$\text{RMSE}_{\text{Train}}$	$\text{RMSE}_{\text{Test}}$	$\text{MAE}_{\text{Train}}$	MAE_{Test}	$\text{MAPE}_{\text{Train}}$	$\text{MAPE}_{\text{Test}}$
总氮	TransformerConv	64	0.0	0.9993	0.9992	0.0163	0.0177	0.0077	0.0086	0.0019	0.0021
总氮	TransformerConv	64	0.1	0.7715	0.7767	0.2878	0.3012	0.2061	0.2304	0.0506	0.0561
总氮	TransformerConv	64	0.2	0.7411	0.7386	0.3063	0.3259	0.2294	0.2505	0.0562	0.0605
总氮	TransformerConv	64	0.3	0.6534	0.6463	0.3544	0.3791	0.2655	0.2842	0.0644	0.0684
总氮	TransformerConv	128	0.0	0.9994	0.9990	0.0147	0.0198	0.0056	0.0072	0.0014	0.0017
总氮	TransformerConv	128	0.1	0.7038	0.6841	0.3276	0.3582	0.2479	0.2641	0.0612	0.0650
总氮	TransformerConv	128	0.2	0.8155	0.8010	0.2586	0.2843	0.1945	0.2180	0.0475	0.0520
总氮	TransformerConv	128	0.3	0.7173	0.7020	0.3200	0.3479	0.2380	0.2642	0.0578	0.0628
总氮	TransformerConv	256	0.0	0.9967	0.9972	0.0346	0.0338	0.0192	0.0189	0.0047	0.0046
总氮	TransformerConv	256	0.1	0.7516	0.7354	0.3000	0.3279	0.2237	0.2490	0.0544	0.0597
总氮	TransformerConv	256	0.2	0.6607	0.6322	0.3506	0.3865	0.2637	0.2933	0.0645	0.0706
总氮	TransformerConv	256	0.3	0.5264	0.4949	0.4143	0.4530	0.3040	0.3323	0.0742	0.0803
总氮	GCNConv	64	0.0	0.9484	0.9458	0.1368	0.1484	0.0935	0.0968	0.0229	0.0235
总氮	GCNConv	64	0.1	0.7772	0.8246	0.2841	0.2669	0.2114	0.2062	0.0515	0.0509
总氮	GCNConv	64	0.2	0.7261	0.7667	0.3150	0.3078	0.2345	0.2367	0.0571	0.0581
总氮	GCNConv	64	0.3	0.6619	0.6822	0.3500	0.3593	0.2628	0.2759	0.0639	0.0673
总氮	GCNConv	128	0.0	0.9778	0.9793	0.0897	0.0918	0.0547	0.0545	0.0136	0.0133
总氮	GCNConv	128	0.1	0.8727	0.8886	0.2148	0.2127	0.1578	0.1566	0.0388	0.0386

续表 5.9 石坎断面目标变量的 STGCN 模型结构组合 (续)

目标变量	卷积类型	隐藏层	丢弃率	R^2_{Train}	R^2_{Test}	$\text{RMSE}_{\text{Train}}$	$\text{RMSE}_{\text{Test}}$	$\text{MAE}_{\text{Train}}$	MAE_{Test}	$\text{MAPE}_{\text{Train}}$	$\text{MAPE}_{\text{Test}}$
总氮	GCNConv	128	0.2	0.7449	0.7690	0.3040	0.3063	0.2268	0.2358	0.0554	0.0578
总氮	GCNConv	128	0.3	0.7993	0.8110	0.2697	0.2771	0.1997	0.2130	0.0492	0.0531
总氮	GCNConv	256	0.0	0.9881	0.9899	0.0658	0.0641	0.0346	0.0324	0.0088	0.0081
总氮	GCNConv	256	0.1	0.9342	0.9396	0.1544	0.1566	0.1102	0.1102	0.0273	0.0273
总氮	GCNConv	256	0.2	0.8912	0.9076	0.1985	0.1938	0.1452	0.1449	0.0358	0.0359
总氮	GCNConv	256	0.3	0.7585	0.7547	0.2958	0.3157	0.2222	0.2408	0.0543	0.0587
总氮	SAGEConv	64	0.0	0.9916	0.9913	0.0551	0.0594	0.0313	0.0337	0.0078	0.0082
总氮	SAGEConv	64	0.1	0.8310	0.8468	0.2474	0.2494	0.1869	0.1909	0.0465	0.0461
总氮	SAGEConv	64	0.2	0.7534	0.7819	0.2989	0.2976	0.2195	0.2271	0.0535	0.0546
总氮	SAGEConv	64	0.3	0.6822	0.6531	0.3393	0.3754	0.2544	0.2824	0.0623	0.0685
总氮	SAGEConv	128	0.0	0.9997	0.9996	0.0111	0.0121	0.0044	0.0050	0.0011	0.0013
总氮	SAGEConv	128	0.1	0.8266	0.8270	0.2507	0.2651	0.1796	0.1977	0.0443	0.0481
总氮	SAGEConv	128	0.2	0.8621	0.8648	0.2236	0.2343	0.1544	0.1699	0.0375	0.0407
总氮	SAGEConv	128	0.3	0.6854	0.6599	0.3376	0.3717	0.2500	0.2760	0.0611	0.0667
总氮	SAGEConv	256	0.0	0.9985	0.9969	0.0235	0.0354	0.0110	0.0150	0.0027	0.0037
总氮	SAGEConv	256	0.1	0.8557	0.8872	0.2286	0.2141	0.1509	0.1509	0.0367	0.0367
总氮	SAGEConv	256	0.2	0.6182	0.6091	0.3720	0.3985	0.2731	0.2967	0.0667	0.0719
总氮	SAGEConv	256	0.3	0.6849	0.6613	0.3379	0.3709	0.2443	0.2701	0.0596	0.0654

续表 5.9 石坎断面目标变量的 STGCN 模型结构组合 (续)

目标变量	卷积类型	隐藏层	丢弃率	R^2_{Train}	R^2_{Test}	$\text{RMSE}_{\text{Train}}$	$\text{RMSE}_{\text{Test}}$	$\text{MAE}_{\text{Train}}$	MAE_{Test}	$\text{MAPE}_{\text{Train}}$	$\text{MAPE}_{\text{Test}}$
总氮	GATConv	64	0.0	0.8872	0.8791	0.2022	0.2216	0.1522	0.1656	0.0376	0.0409
总氮	GATConv	64	0.1	0.8028	0.8008	0.2673	0.2845	0.2009	0.2201	0.0492	0.0538
总氮	GATConv	64	0.2	0.7944	0.7741	0.2729	0.3029	0.2063	0.2256	0.0504	0.0541
总氮	GATConv	64	0.3	0.7310	0.6894	0.3122	0.3552	0.2318	0.2594	0.0560	0.0619
总氮	GATConv	128	0.0	0.9598	0.9607	0.1207	0.1264	0.0824	0.0844	0.0203	0.0207
总氮	GATConv	128	0.1	0.9089	0.9084	0.1817	0.1929	0.1339	0.1433	0.0328	0.0350
总氮	GATConv	128	0.2	0.8943	0.9002	0.1957	0.2013	0.1453	0.1534	0.0357	0.0373
总氮	GATConv	128	0.3	0.8617	0.8634	0.2238	0.2355	0.1693	0.1782	0.0413	0.0429
总氮	GATConv	256	0.0	0.9916	0.9928	0.0552	0.0541	0.0267	0.0275	0.0065	0.0066
总氮	GATConv	256	0.1	0.9671	0.9643	0.1091	0.1204	0.0757	0.0822	0.0187	0.0202
总氮	GATConv	256	0.2	0.9523	0.9407	0.1314	0.1552	0.0949	0.1091	0.0231	0.0263
总氮	GATConv	256	0.3	0.9206	0.9051	0.1696	0.1963	0.1246	0.1420	0.0304	0.0345
总磷	TransformerConv	64	0.0	0.9941	0.9945	0.0047	0.0044	0.0021	0.0021	0.0126	0.0122
总磷	TransformerConv	64	0.1	0.9280	0.9210	0.0163	0.0167	0.0121	0.0127	0.0664	0.0671
总磷	TransformerConv	64	0.2	0.8962	0.8842	0.0196	0.0202	0.0145	0.0151	0.0800	0.0792
总磷	TransformerConv	64	0.3	0.7786	0.7852	0.0286	0.0275	0.0216	0.0212	0.1217	0.1146
总磷	TransformerConv	128	0.0	0.9956	0.9962	0.0041	0.0036	0.0012	0.0013	0.0069	0.0066
总磷	TransformerConv	128	0.1	0.9584	0.9490	0.0124	0.0134	0.0088	0.0098	0.0485	0.0519

续表 5.9 石坎断面目标变量的 STGCN 模型结构组合 (续)

目标变量	卷积类型	隐藏层	丢弃率	R^2_{Train}	R^2_{Test}	$\text{RMSE}_{\text{Train}}$	$\text{RMSE}_{\text{Test}}$	$\text{MAE}_{\text{Train}}$	MAE_{Test}	$\text{MAPE}_{\text{Train}}$	$\text{MAPE}_{\text{Test}}$
总磷	TransformerConv	128	0.2	0.8353	0.8383	0.0247	0.0238	0.0185	0.0179	0.1014	0.0910
总磷	TransformerConv	128	0.3	0.7815	0.7767	0.0284	0.0280	0.0214	0.0221	0.1185	0.1152
总磷	TransformerConv	256	0.0	0.7603	0.7813	0.0298	0.0277	0.0226	0.0216	0.1224	0.1118
总磷	TransformerConv	256	0.1	0.9107	0.9179	0.0182	0.0170	0.0128	0.0123	0.0709	0.0664
总磷	TransformerConv	256	0.2	0.7324	0.7382	0.0315	0.0303	0.0235	0.0241	0.1302	0.1270
总磷	TransformerConv	256	0.3	0.6009	0.6184	0.0384	0.0366	0.0291	0.0292	0.1600	0.1539
总磷	GCNConv	64	0.0	0.9351	0.9413	0.0155	0.0144	0.0110	0.0107	0.0592	0.0567
总磷	GCNConv	64	0.1	0.8175	0.8567	0.0260	0.0224	0.0191	0.0170	0.1046	0.0894
总磷	GCNConv	64	0.2	0.7813	0.8040	0.0284	0.0262	0.0212	0.0206	0.1150	0.1070
总磷	GCNConv	64	0.3	0.7391	0.7804	0.0311	0.0278	0.0232	0.0219	0.1272	0.1141
总磷	GCNConv	128	0.0	0.9842	0.9858	0.0076	0.0071	0.0044	0.0046	0.0241	0.0236
总磷	GCNConv	128	0.1	0.9030	0.9163	0.0189	0.0171	0.0137	0.0131	0.0753	0.0690
总磷	GCNConv	128	0.2	0.9143	0.9198	0.0178	0.0168	0.0131	0.0129	0.0706	0.0657
总磷	GCNConv	128	0.3	0.8595	0.8842	0.0228	0.0202	0.0167	0.0155	0.0913	0.0829
总磷	GCNConv	256	0.0	0.9954	0.9971	0.0041	0.0032	0.0015	0.0016	0.0089	0.0082
总磷	GCNConv	256	0.1	0.9249	0.9267	0.0167	0.0160	0.0120	0.0121	0.0661	0.0641
总磷	GCNConv	256	0.2	0.9397	0.9436	0.0149	0.0141	0.0107	0.0102	0.0586	0.0540
总磷	GCNConv	256	0.3	0.8407	0.8624	0.0243	0.0220	0.0179	0.0167	0.0965	0.0870

续表 5.9 石坎断面目标变量的 STGCN 模型结构组合 (续)

目标变量	卷积类型	隐藏层	丢弃率	R^2_{Train}	R^2_{Test}	$\text{RMSE}_{\text{Train}}$	$\text{RMSE}_{\text{Test}}$	$\text{MAE}_{\text{Train}}$	MAE_{Test}	$\text{MAPE}_{\text{Train}}$	$\text{MAPE}_{\text{Test}}$
总磷	SAGEConv	64	0.0	0.9943	0.9932	0.0046	0.0049	0.0020	0.0022	0.0119	0.0135
总磷	SAGEConv	64	0.1	0.8587	0.8550	0.0229	0.0226	0.0166	0.0172	0.0905	0.0886
总磷	SAGEConv	64	0.2	0.8442	0.8549	0.0240	0.0226	0.0181	0.0176	0.0998	0.0919
总磷	SAGEConv	64	0.3	0.7819	0.7905	0.0284	0.0271	0.0213	0.0210	0.1175	0.1086
总磷	SAGEConv	128	0.0	0.9986	0.9982	0.0023	0.0025	0.0009	0.0009	0.0055	0.0053
总磷	SAGEConv	128	0.1	0.9411	0.9357	0.0148	0.0150	0.0101	0.0109	0.0556	0.0571
总磷	SAGEConv	128	0.2	0.9391	0.9357	0.0150	0.0150	0.0108	0.0112	0.0597	0.0590
总磷	SAGEConv	128	0.3	0.8490	0.8498	0.0236	0.0230	0.0175	0.0176	0.0964	0.0907
总磷	SAGEConv	256	0.0	0.9987	0.9979	0.0022	0.0027	0.0006	0.0008	0.0040	0.0047
总磷	SAGEConv	256	0.1	0.9401	0.9335	0.0149	0.0153	0.0101	0.0111	0.0542	0.0575
总磷	SAGEConv	256	0.2	0.9337	0.9254	0.0157	0.0162	0.0112	0.0120	0.0608	0.0627
总磷	SAGEConv	256	0.3	0.8846	0.8852	0.0207	0.0201	0.0153	0.0152	0.0831	0.0801
总磷	GATConv	64	0.0	0.9332	0.9403	0.0157	0.0145	0.0112	0.0106	0.0612	0.0554
总磷	GATConv	64	0.1	0.8587	0.8436	0.0229	0.0234	0.0174	0.0184	0.0954	0.0956
总磷	GATConv	64	0.2	0.8410	0.8474	0.0242	0.0231	0.0178	0.0179	0.0951	0.0915
总磷	GATConv	64	0.3	0.7653	0.7622	0.0295	0.0289	0.0224	0.0230	0.1217	0.1197
总磷	GATConv	128	0.0	0.9777	0.9811	0.0091	0.0081	0.0051	0.0051	0.0272	0.0248
总磷	GATConv	128	0.1	0.9352	0.9422	0.0155	0.0142	0.0111	0.0105	0.0605	0.0549

续表 5.9 石坎断面目标变量的 STGCN 模型结构组合 (续)

目标变量	卷积类型	隐藏层	丢弃率	R^2_{Train}	R^2_{Test}	$\text{RMSE}_{\text{Train}}$	$\text{RMSE}_{\text{Test}}$	$\text{MAE}_{\text{Train}}$	MAE_{Test}	$\text{MAPE}_{\text{Train}}$	$\text{MAPE}_{\text{Test}}$
总磷	GATConv	128	0.2	0.9038	0.8998	0.0189	0.0188	0.0137	0.0142	0.0742	0.0726
总磷	GATConv	128	0.3	0.9099	0.9013	0.0183	0.0186	0.0135	0.0144	0.0734	0.0740
总磷	GATConv	256	0.0	0.9889	0.9906	0.0064	0.0057	0.0027	0.0028	0.0144	0.0148
总磷	GATConv	256	0.1	0.9660	0.9685	0.0112	0.0105	0.0066	0.0067	0.0359	0.0345
总磷	GATConv	256	0.2	0.9727	0.9750	0.0100	0.0094	0.0064	0.0064	0.0356	0.0328
总磷	GATConv	256	0.3	0.9302	0.9212	0.0161	0.0166	0.0114	0.0125	0.0619	0.0642
氨氮	TransformerConv	64	0.0	0.9986	0.9992	0.0049	0.0034	0.0016	0.0015	0.3027	0.2937
氨氮	TransformerConv	64	0.1	0.8786	0.8452	0.0451	0.0473	0.0336	0.0345	8.6024	5.9781
氨氮	TransformerConv	64	0.2	0.7496	0.7018	0.0647	0.0656	0.0466	0.0467	10.4262	8.4589
氨氮	TransformerConv	64	0.3	0.7184	0.6938	0.0686	0.0665	0.0508	0.0492	11.4510	7.5462
氨氮	TransformerConv	128	0.0	0.9994	0.9990	0.0031	0.0038	0.0008	0.0010	0.1389	0.1085
氨氮	TransformerConv	128	0.1	0.9421	0.9261	0.0311	0.0327	0.0218	0.0223	5.3076	3.4898
氨氮	TransformerConv	128	0.2	0.7275	0.7019	0.0675	0.0656	0.0465	0.0447	10.5148	6.5601
氨氮	TransformerConv	128	0.3	0.6045	0.5501	0.0814	0.0806	0.0586	0.0571	12.5278	9.1404
氨氮	TransformerConv	256	0.0	0.9997	0.9993	0.0023	0.0031	0.0006	0.0007	0.1237	0.0349
氨氮	TransformerConv	256	0.1	0.6477	0.6304	0.0768	0.0731	0.0533	0.0509	10.8977	7.0073
氨氮	TransformerConv	256	0.2	0.5181	0.5133	0.0898	0.0838	0.0645	0.0598	13.4368	9.3565
氨氮	TransformerConv	256	0.3	0.6036	0.5371	0.0814	0.0818	0.0582	0.0560	12.1358	8.4965

续表 5.9 石坎断面目标变量的 STGCN 模型结构组合 (续)

目标变量	卷积类型	隐藏层	丢弃率	R^2_{Train}	R^2_{Test}	$\text{RMSE}_{\text{Train}}$	$\text{RMSE}_{\text{Test}}$	$\text{MAE}_{\text{Train}}$	MAE_{Test}	$\text{MAPE}_{\text{Train}}$	$\text{MAPE}_{\text{Test}}$
氨氮	GCNConv	64	0.0	0.9073	0.8786	0.0394	0.0419	0.0277	0.0293	6.4868	5.9759
氨氮	GCNConv	64	0.1	0.7785	0.7074	0.0609	0.0650	0.0440	0.0482	10.7026	8.6958
氨氮	GCNConv	64	0.2	0.6055	0.5677	0.0813	0.0790	0.0588	0.0560	13.2097	9.5393
氨氮	GCNConv	64	0.3	0.5934	0.5554	0.0825	0.0801	0.0580	0.0558	12.1307	8.7113
氨氮	GCNConv	128	0.0	0.9461	0.9314	0.0300	0.0315	0.0190	0.0204	4.0465	4.2417
氨氮	GCNConv	128	0.1	0.8096	0.7625	0.0564	0.0586	0.0401	0.0417	9.1180	7.6165
氨氮	GCNConv	128	0.2	0.6187	0.5896	0.0799	0.0770	0.0561	0.0521	12.4360	9.2239
氨氮	GCNConv	128	0.3	0.5792	0.5408	0.0839	0.0814	0.0596	0.0566	12.7531	9.1713
氨氮	GCNConv	256	0.0	0.9768	0.9712	0.0197	0.0204	0.0111	0.0115	2.6218	3.1508
氨氮	GCNConv	256	0.1	0.7565	0.6947	0.0638	0.0664	0.0425	0.0435	8.7437	7.1766
氨氮	GCNConv	256	0.2	0.6470	0.6328	0.0769	0.0728	0.0521	0.0478	11.1687	7.9544
氨氮	GCNConv	256	0.3	0.6543	0.6440	0.0761	0.0717	0.0523	0.0480	10.8672	8.0423
氨氮	SAGEConv	64	0.0	0.9942	0.9905	0.0098	0.0117	0.0048	0.0059	0.8586	0.4316
氨氮	SAGEConv	64	0.1	0.8940	0.8821	0.0421	0.0413	0.0291	0.0282	6.4613	3.9573
氨氮	SAGEConv	64	0.2	0.7232	0.7309	0.0681	0.0623	0.0484	0.0440	11.3737	6.9479
氨氮	SAGEConv	64	0.3	0.6116	0.5986	0.0806	0.0761	0.0580	0.0542	12.8633	7.9703
氨氮	SAGEConv	128	0.0	0.9992	0.9991	0.0037	0.0035	0.0014	0.0015	0.1993	0.0935
氨氮	SAGEConv	128	0.1	0.8353	0.8074	0.0525	0.0527	0.0359	0.0345	8.0348	6.5443

续表 5.9 石坎断面目标变量的 STGCN 模型结构组合 (续)

目标变量	卷积类型	隐藏层	丢弃率	R^2_{Train}	R^2_{Test}	$\text{RMSE}_{\text{Train}}$	$\text{RMSE}_{\text{Test}}$	$\text{MAE}_{\text{Train}}$	MAE_{Test}	$\text{MAPE}_{\text{Train}}$	$\text{MAPE}_{\text{Test}}$
氨氮	SAGEConv	128	0.2	0.7294	0.7259	0.0673	0.0629	0.0463	0.0416	10.1102	5.9584
氨氮	SAGEConv	128	0.3	0.6554	0.6434	0.0759	0.0718	0.0546	0.0515	12.5470	8.5592
氨氮	SAGEConv	256	0.0	0.9368	0.9398	0.0325	0.0295	0.0164	0.0170	2.5435	1.5862
氨氮	SAGEConv	256	0.1	0.7147	0.6627	0.0691	0.0698	0.0473	0.0471	10.5129	7.4385
氨氮	SAGEConv	256	0.2	0.6739	0.6579	0.0739	0.0703	0.0516	0.0476	11.0310	7.6591
氨氮	SAGEConv	256	0.3	0.6357	0.6037	0.0781	0.0756	0.0546	0.0517	11.8513	7.9184
氨氮	GATConv	64	0.0	0.8874	0.8455	0.0434	0.0472	0.0301	0.0320	7.2751	5.1871
氨氮	GATConv	64	0.1	0.7096	0.6349	0.0697	0.0726	0.0493	0.0512	11.5933	8.7868
氨氮	GATConv	64	0.2	0.7558	0.6868	0.0639	0.0673	0.0456	0.0487	10.9091	7.5702
氨氮	GATConv	64	0.3	0.6872	0.6299	0.0723	0.0731	0.0518	0.0528	11.4675	8.1787
氨氮	GATConv	128	0.0	0.9834	0.9759	0.0167	0.0187	0.0091	0.0097	1.7456	1.6528
氨氮	GATConv	128	0.1	0.9242	0.8875	0.0356	0.0403	0.0246	0.0281	6.4855	4.7336
氨氮	GATConv	128	0.2	0.8103	0.7580	0.0563	0.0591	0.0398	0.0426	9.3386	7.7149
氨氮	GATConv	128	0.3	0.8465	0.7885	0.0507	0.0553	0.0359	0.0395	8.2322	5.9674
氨氮	GATConv	256	0.0	0.9895	0.9800	0.0132	0.0170	0.0069	0.0086	1.8188	1.2191
氨氮	GATConv	256	0.1	0.9196	0.8939	0.0367	0.0391	0.0252	0.0268	6.0163	3.4543
氨氮	GATConv	256	0.2	0.9296	0.8992	0.0343	0.0382	0.0239	0.0256	5.8506	3.8466
氨氮	GATConv	256	0.3	0.9342	0.8940	0.0332	0.0391	0.0230	0.0270	5.3778	4.2433

表 5.10 石坎断面 STGCN 模型最优超参数与评价指标

目标变量	总氮	总磷	氨氮
卷积类型	SAGEConv	SAGEConv	TransformerConv
隐藏层	128	256	256
丢弃率	0.0	0.0	0.0
R^2_{Train}	0.9997	0.9987	0.9997
R^2_{Test}	0.9996	0.9979	0.9993
$\text{RMSE}_{\text{Train}}$	0.0111	0.0022	0.0023
$\text{RMSE}_{\text{Test}}$	0.0121	0.0027	0.0031
$\text{MAE}_{\text{Train}}$	0.0044	0.0006	0.0006
MAE_{Test}	0.0050	0.0008	0.0007
$\text{MAPE}_{\text{Train}}$	0.0011	0.0040	0.1237
$\text{MAPE}_{\text{Test}}$	0.0013	0.0047	0.0349

注：表中 RMSE 与 MAE 的单位均为 mg/L。

5.7 ANN 模型与 STGCN 模型的对比分析

为进一步验证 STGCN 模型在水质预测中的性能优势，本节选取前文构建的 ANN 模型作为对照，分析两者在不同水质指标下的表现差异。ANN 模型仅依赖时间序列特征进行建模，而 STGCN 模型则在此基础上进一步融合了空间结构信息，能够同时捕捉污染物的时间动态和空间依赖关系。

从表 5.11 可以看出，在清水铺断面的水质时间序列预测任务中，STGCN 模型在氨氮（ $\text{NH}_4^+\text{-N}$ ）、总磷（TP）和总氮（TN）三个目标变量上的预测性能均明显优于 ANN 模型。以测试集为例，STGCN 模型在氨氮的 RMSE、MAE 和 MAPE 指标上，分别比 ANN 模型降低了 80.56%、96.07% 和 99.72%；在总磷上分别降低了 62.50%、59.57% 和 99.67%；在总氮上分别降低了 45.45%、31.12% 和 99.51%。此外，三个变量的 R^2 值也分别提升了 0.2143、0.1403 和 0.1854，显示出更强的拟合能力和更低的预测误差。

这种显著的性能差异不仅体现了 STGCN 模型在整合时空信息方面的结构优势，更重要的是，它在建模过程中融合了更多与流域特征相关的信息，如地形、水系和植被覆盖等对水质变化具有潜在影响的因子。相比之下，ANN 模型主要依赖时间序列建模，虽在处理局部时间变化方面具备一定能力，但由于未能有效整合空间结构和流域背景信息，其在刻画污染扩散路径和空间关联性方面存在局限。

表 5.11 ANN 模型与 STGCN 模型对比分析

模型	断面	变量	数据集	R^2	RMSE	MAE	MAPE
ANN	清水铺	氨氮	训练集	0.9819	0.0150	0.0309	0.3635
			测试集	0.7774	0.0072	0.0280	0.3210
		总磷	训练集	0.9870	0.0024	0.0040	0.1218
			测试集	0.8496	0.0144	0.0047	0.1450
		总氮	训练集	0.9937	0.0709	0.0325	0.0109
			测试集	0.7494	0.2233	0.1086	0.0362
STGCN	石坎	氨氮	训练集	0.9991	0.0040	0.0019	0.3894
			测试集	0.9985	0.0046	0.0020	0.1792
		总磷	训练集	0.9997	0.0011	0.0002	0.0012
			测试集	0.9990	0.0018	0.0003	0.0018
		总氮	训练集	0.9999	0.0073	0.0029	0.0007
			测试集	0.9999	0.0063	0.0028	0.0007
	清水铺	氨氮	训练集	1.0000	0.0006	0.0005	28.4184
			测试集	0.9917	0.0014	0.0011	0.0897
		总磷	训练集	1.0000	0.0001	0.0001	0.0049
			测试集	0.9899	0.0054	0.0019	0.0473
		总氮	训练集	1.0000	0.0045	0.0030	0.0010
			测试集	0.9348	0.1218	0.0748	0.0179

注：表中 RMSE 与 MAE 的单位均为 mg/L。

以赤水河流域为例，该区域土地利用类型相对单一，以耕地和林地为主，空间结构较为清晰，为模型引入流域特征提供了良好的实验基础。STGCN 模型通过图神经网络结构引入网格间空间邻接关系，并整合多源流域特征信息，从而增强了对污染物传输机制和演变趋势的感知能力，实现更稳定、更高精度的预测。

综上所述，STGCN 模型凭借对流域多维信息的融合能力，在水质预测任务中展现出相较 ANN 更强的泛化性能与适应性，为构建高效、智能的流域水质预警体系提供了有效支撑。

5.8 本章小结

本章围绕基于 STGCN 的流域水质时空预测模型展开系统研究，取得了以下主要成果：

首先，选取赤水河流域石坎断面为典型区域，融合气象、水质、遥感与污水

排放等多源数据，采用相关性分析与递归特征消除方法筛选出各目标变量的关键输入特征，并构建包含空间邻接结构的图神经网络模型。模型采用多种图卷积结构与超参数组合进行性能测试，最终筛选出适用于氨氮、总磷与总氮预测的最优 STGCN 结构组合。模型在测试集上均取得 $R^2 > 0.99$ 的预测精度，RMSE 与 MAPE 控制在极低水平，验证了其较强的拟合能力与稳定性。

其次，通过引入特征重要性分析方法识别模型中主导变量，发现气象、水质变量和遥感波段对预测表现具有重要影响，说明 STGCN 模型不仅具备数据驱动的建模优势，也能在一定程度上揭示污染演化的内在机制。基于预测结果构建了水质预警机制，对氨氮、总磷与总氮的超标时段进行了有效识别，展示了模型在环境管理中的实用价值。

进一步地，通过将子流域 10 构建的模型迁移至子流域 14 的清水铺断面，并与 ANN 模型进行对比分析，验证了 STGCN 模型在不同地理单元中的泛化能力以及在整合时空特征下的精度优势。此外，在剔除所有水质类输入的情况下，STGCN 模型依然能凭借遥感与气象数据实现高精度预测，显示出其在数据稀缺情境中的适应能力和推广前景。

综上所述，STGCN 模型在流域水质建模中的应用展现出显著的优势，可有效提升预测精度、拓展模型适用范围，为构建高时效、高空间分辨率的水质预警系统提供了强有力的技术支撑。

第 6 章 结论与建议

6.1 结论

本研究以赤水河云南段流域为案例区，面向流域尺度的水质动态模拟预测与预警需求，融合遥感、气象、水质和污染排放等多源数据，系统开展了基于 ANN 与 STGCN 模型的构建与比较研究，取得以下主要结论：

(1) 多源数据融合与输入变量筛选为模型性能提供坚实基础。本研究构建了融合遥感、气象、水质和污水处理厂数据的高时空分辨率输入数据体系，采用相关性分析与递归特征消除方法相结合的方式，科学筛选出总氮、总磷和氨氮等典型水质指标的关键驱动因子，有效减少了冗余变量，提升了模型稳定性与泛化能力。

(2) 模型具备良好的可解释性与预警能力，可辅助流域水质管理决策。通过归一化特征重要性计算，明确了气象、水质、遥感波段等变量对水质预测结果的重要贡献，揭示了污染演化的内在驱动机制。在此基础上，构建了基于国家水质标准的阈值预警机制，可准确识别水质超标时段，增强了模型在实际环境管理中的实用性。

(3) ANN 模型在时间序列建模中表现良好，但在处理波动性较大或浓度较低的水质指标时有局限性。在清水铺断面的建模中，ANN 模型对部分污染物的短期趋势拟合效果较好， R^2 值可超过 0.75。但在面对浓度低、波动性强、受多重因素驱动的水质指标时，模型预测精度明显下降，误差波动较大。该现象表明，基于时间序列建模的 ANN 模型在特征学习能力和异常变化捕捉方面仍存在局限，难以充分应对复杂污染过程下的高频扰动与微弱信号。

(4) STGCN 模型显著提升了时空建模能力，在预测精度与稳定性方面均优于 ANN 模型。在石坎与清水铺断面构建的 STGCN 模型中，三个目标变量在测试集上的 R^2 均超过 0.93，RMSE 与 MAPE 指标表现也显著优于 ANN 模型。STGCN 模型通过图结构引入空间邻接信息，有效捕捉了污染物的空间依赖性和时间动态过程，表现出更强的拟合能力与稳健性。

(5) STGCN 模型具备较强的跨区域迁移能力与数据缺失适应能力，具推广潜力。通过将子流域 10 构建的 STGCN 模型迁移至清水铺断面所在的子流域 14，并与 ANN 模型进行对比，验证了其区域泛化能力。在剔除所有水质观测变量后，STGCN 模型仍能在仅依赖气象与遥感数据的条件下实现高精度预测，表明其在数

据稀缺流域中的应用前景广阔。

综上所述，构建数据驱动模型可作为流域管理与水质预测预警的重要技术补充。STGCN 模型在时空特征提取、预测精度提升与实用性拓展方面均展现出显著优势，可为构建高分辨率、广覆盖的水质预测与预警体系提供技术支撑。研究结果对多源数据驱动的流域环境建模、污染防控与生态调控具有重要参考价值。

6.2 建议

本研究构建的 STGCN 模型在融合多源数据、提升水质预测精度等方面取得了积极进展，未来研究仍可在以下两个方向进一步深化：

（1）加强多源数据的时效性与动态特征建模。模型性能在很大程度上依赖于输入数据的时效性与质量，未来可进一步探索多源数据流的实时接入机制，提升遥感反演、水文监测及污染排放数据的更新频率与空间分辨率。同时，建议结合缺失数据修复与动态特征提取方法，增强模型对时变输入的不确定性适应能力，为时序预测任务提供更稳定的输入支持。

（2）拓展模型输出在情景模拟与政策支持中的应用潜力。为实现科研成果向管理实践的有效转化，未来可将 STGCN 模型预测结果与污染治理情景模拟相结合，构建基于数据驱动的治理成效评估框架，探索模型在区域减排方案对比、敏感区识别与治理优先级排序等方面的辅助决策价值。

参考文献

- [1] 中华人民共和国生态环境部. 2023 中国生态环境状况公报[EB/OL]. 2023. <https://www.mee.gov.cn/hjzl/sthjzk/zghjzkgb/>.
- [2] 中华人民共和国生态环境部. “十四五”重点流域水环境综合治理规划[Z]. 2021.
- [3] Cox B A. A review of currently available in-stream water quality models and their applicability for simulating dissolved oxygen in lowland rivers[J]. *Science of the Total Environment*, 2003, 314: 335-377.
- [4] Chapra S C. *Surface water quality modeling*[M]. New York: McGraw-Hill Companies, Inc., 2008.
- [5] Jha M K, Gupta A D. Application of mike basin for water management strategies in a watershed [J]. *Water International*, 2003, 28(1): 27-35.
- [6] Ejigu M T. Overview of water quality modeling[J/OL]. *Cogent Engineering*, 2021, 8(1). DOI: 10.1080/23311916.2021.1891711.
- [7] Shen Z, Qiu J, Hong Q, et al. Simulation of spatial and temporal distributions of non-point source pollution load in the three gorges reservoir region[J/OL]. *Science of the Total Environment*, 2014, 493: 138-146. DOI: 10.1016/j.scitotenv.2014.05.109.
- [8] McKenna S A, Klise K A, Wilson M P. Testing water quality change detection algorithms[C]// *Proceedings of the Eighth Water Distribution Systems Analysis Symposium*. Cincinnati, Ohio, 2006: 1-15.
- [9] Zou L, Liu Y, Wang Y, et al. Assessment and analysis of agricultural non-point source pollution loads in china: 1978-2017[J/OL]. *Journal of Environmental Management*, 2020, 263: 110400. DOI: 10.1016/j.jenvman.2020.110400.
- [10] Mekonnen M M, Hoekstra A Y. Global gray water footprint and water pollution levels related to anthropogenic nitrogen loads to fresh water[J/OL]. *Environmental Science & Technology*, 2015, 49(21): 12860-12868. DOI: 10.1021/acs.est.5b03191.
- [11] Bui D T, Khosravi K, Tiefenbacher J, et al. Improving prediction of water quality indices using novel hybrid machine-learning algorithms[J]. *Science of the Total Environment*, 2020, 731: 139113.
- [12] Rajae T, Khani S, Ravansalar M. Artificial intelligence-based single and hybrid models for prediction of water quality in rivers: A review[J]. *Chemometrics and Intelligent Laboratory Systems*, 2020, 200: 104000.

- [13] Lu H, Ma X. Hybrid decision tree-based machine learning models for short-term water quality prediction[J]. *Chemosphere*, 2020, 249: 126169.
- [14] Ahmed U, Mumtaz R, Anwar H, et al. Efficient water quality prediction using supervised machine learning[J/OL]. *Water*, 2019, 11(11): 2210. DOI: 10.3390/w1111221.
- [15] Nasir N, Kansal A, Alshaltoni O, et al. Water quality classification using machine learning algorithms[J/OL]. *Journal of Water Process Engineering*, 2022, 48: 102920. DOI: 10.1016/j.jwpe.2022.102920.
- [16] Abba S I, Jasim S, Abdullahi J. River water modelling prediction using multilinear regression, artificial neural network, and adaptive neuro-fuzzy inference system techniques[J/OL]. *Procedia Computer Science*, 2017, 120: 75-82. DOI: 10.1016/j.procs.2017.11.216.
- [17] Heddam S. Multilayer perceptron neural network-based approach for modeling phycocyanin pigment concentrations: case study from lower charles river buoy, usa[J]. *Environmental Science and Pollution Research*, 2016, 23: 17210-17225.
- [18] Barzegar R, Asghari Moghaddam A, Adamowski J, et al. Multi-step water quality forecasting using a boosting ensemble multi-wavelet extreme learning machine model[J]. *Stochastic Environmental Research and Risk Assessment*, 2018, 32: 799-813.
- [19] Zhang K, Shen J, Han H, et al. Urban river health analysis of the jialu river in zhengzhou city using the improved fuzzy matter-element extension model[J]. *Water*, 2019, 11: 1190.
- [20] Gupta D, Mishra V K. Development of entropy-river water quality index for predicting water quality classification through machine learning approach[J/OL]. *Stochastic Environmental Research and Risk Assessment*, 2023, 37(11): 4249-4271. DOI: 10.1007/s00477-023-02265-9.
- [21] Barzegar R, Aalami M T, Adamowski J. Short-term water quality variable prediction using a hybrid cnn – lstm deep learning model[J/OL]. *Stochastic Environmental Research and Risk Assessment*, 2020, 34(6): 1761-1773. DOI: 10.1007/s00477-020-01776-2.
- [22] Li X, et al. Multi-source data machine learning-based study on method for regional water quality prediction[J]. *Water Resources and Hydropower Engineering*, 2023, 52(11): 152-163.
- [23] Chen L, Zhang H, Wu J, et al. A hybrid model for water quality prediction integrating hydrodynamic models and lightgbm[J/OL]. *Environmental Science & Technology*, 2023, 57(5): 1275-1285. DOI: 10.1021/acs.est.2c06289.
- [24] Tiyyasha, Tung T M, Yaseen Z M. A survey on river water quality modelling using artificial intelligence models: 2000 – 2020[J/OL]. *Journal of Hydrology*, 2020, 585: 124670. DOI: 10.1016/j.jhydrol.2020.124670.
- [25] Shi B, Wang P, Jiang J, et al. Applying high-frequency surrogate measurements and a wavelet-ann model to provide early warnings of rapid surface water quality anomalies[J/OL]. *Science of the Total Environment*, 2018, 610–611: 1397-1405. DOI: 10.1016/j.scitotenv.2017.08.177.

- [26] Che R, Lin S, Fan Z, 等. 连续极端降雨对东江流域水质影响分析[J]. 环境科学, 2019, 40 (10): 4440-4449.
- [27] Barbhuiya S. Large area hydrologic modeling and assessment[J/OL]. Journal of Earth System Science, 2024. DOI: 10.1007/s12040-024-02340-0.
- [28] Arnold J G, Srinivasan R, Muttiah R S, et al. Large area hydrologic modeling and assessment: Part i. model development[J/OL]. Journal of the American Water Resources Association, 1998, 34(1): 73-89. DOI: 10.1111/j.1752-1688.1998.tb05961.x.
- [29] Neitsch S L, Arnold J G, Kiniry J R, et al. Soil and water assessment tool theoretical documentation version 2009[M]. Texas Water Resources Institute, 2011.
- [30] Gassman P W, Reyes M R, Green C H, et al. The soil and water assessment tool: Historical development, applications, and future research directions[J/OL]. Transactions of the ASABE, 2007, 50(4): 1211-1250. DOI: 10.13031/2013.23637.
- [31] White M J, Storm D E, Busteed P R, et al. Evaluating nonpoint source critical source area contributions at the watershed scale[J/OL]. Journal of Environmental Quality, 2010, 39(4): 1656-1664. DOI: 10.2134/jeq2009.0473.
- [32] Abba S I, Jasim S, Abdullahi J. River water modelling prediction using multilinear regression, artificial neural network, and adaptive neuro-fuzzy inference system techniques[J]. Procedia Computer Science, 2017, 120: 75-82.
- [33] Che R, Lin S, Fan Z, 等. 连续极端降雨对东江流域水质影响分析[J]. 环境科学, 2019, 40 (10): 4440-4449.
- [34] Ficklin D L, Luo Y, Stewart I T, et al. Climate change impacts on streamflow and subbasin-scale hydrology in the upper colorado river basin[J/OL]. PLoS ONE, 2013, 8(8): e71297. DOI: 10.1371/journal.pone.0071297.
- [35] Gazzaz N M, Yusoff M K, Ramli M F, et al. Artificial neural network modeling of the water quality index using land use areas as predictors[J/OL]. Water Environment Research, 2015, 87 (2): 99-112. DOI: 10.2175/106143015X14212658612910.
- [36] Liu J, Zhang Y, Wang Q, et al. Identifying key environmental factors controlling riverine nitrogen and phosphorus loads using redundancy analysis[J/OL]. Science of the Total Environment, 2019, 668: 576-588. DOI: 10.1016/j.scitotenv.2019.02.313.
- [37] Barzegar R, Aalami M T, Adamowski J. Multi-step water quality forecasting using a boosting ensemble multi-wavelet extreme learning machine model[J/OL]. Stochastic Environmental Research and Risk Assessment, 2020, 32(3): 799-813. DOI: 10.1007/s00477-020-01776-2.
- [38] Zhang K, Shen J, Han H, et al. Combining multivariate analysis techniques to assess the influence of land use and hydrological changes on river water quality[J/OL]. Environmental Monitoring and Assessment, 2020, 192(6): 400. DOI: 10.1007/s10661-020-08269-8.

- [39] Zhang W, Wang Y, Peng H, et al. A comprehensive weight-based approach combining entropy weighting with the pearson correlation coefficient for feature selection in water quality prediction[J]. *Entropy*, 2021, 23(8): 1186.
- [40] Zheng Z, Jiang Y, Zhang Q, et al. A feature selection method based on relief feature ranking with recursive feature elimination for the inversion of urban river water quality parameters using multispectral imagery from an unmanned aerial vehicle[J]. *Water*, 2024, 16(7): 1029.
- [41] U.S. EPA. Drinking water treatment source water early warning system state of the science review: EPA/600/R-17/405[R]. Washington, DC: U.S. Environmental Protection Agency, 2017.
- [42] Diehl P, et al. Early warning strategies and practices along the river rhine[M/OL]. Berlin, Heidelberg: Springer, 2005. DOI: 10.1007/698_5_015.
- [43] United Nations Office for Disaster Risk Reduction (UNDRR). Words into action (wia)[R/OL]. 2023. <https://www.undrr.org/words-into-action/guide-multi-hazard-early-warning>.
- [44] Balk F, Okkerman P C, van Helmond C A M, et al. Biological early warning systems for surface water and industrial effluents[J]. *Water Science & Technology*, 1994, 29(3): 211-213.
- [45] Tryland I, Surman S, Berg J D. Monitoring faecal contamination of the thames estuary using a semi-automated early warning system[J]. *Water Science & Technology*, 2002, 46(3): 25-31.
- [46] Izydorczyk K, Tarczyska M, Jurczak T, et al. Measurement of phycocyanin fluorescence as an online early warning system for cyanobacteria in reservoir intake water[J]. *Environmental Toxicology*, 2005, 20: 425-430.
- [47] United States Environmental Protection Agency (USEPA). Technologies and techniques for early warning systems to monitor and evaluate drinking water quality: A state-of-the-art review: EPA/600/R-05/156[R]. Cincinnati: Office of Research and Development, National Homeland Security Research Center, 2005.
- [48] Quansah J E, Engel B, Rochon G L. Early warning systems: A review[J]. *Journal of Terrestrial Observation*, 2010, 2: 23-44.
- [49] Hofmann J, Schüttrumpf H. Risk-based and hydrodynamic pluvial flood forecasts in real time [J/OL]. *Water*, 2020, 12(7): 1895. DOI: 10.3390/w12071895.
- [50] Starzec M, Pawlowska B, Wisniewski P. Assessment of the feasibility of implementing a flash flood early warning system in a small catchment area[J/OL]. *Sustainability*, 2023, 15(10): 8316. DOI: 10.3390/su15108316.
- [51] Papadimitriou A G, Chatzopoulos K, Mimikou M. A novel input schematization method for coastal flooding early warning systems incorporating climate change impacts[J/OL]. *Climate*, 2024, 12(11): 178. DOI: 10.3390/cli12110178.

- [52] Xia X, Qian Y, Wang H, et al. Multisensor early warning system applied to environmental management[J]. Environmental Engineering Science, 2015, 32(4): 263-272.
- [53] Bartlett J A, Dedekorkut-Howes A. Adaptation strategies for climate change impacts on water quality: A systematic review of the literature[J]. Journal of Water and Climate Change, 2022, 14(3): 651-675.
- [54] Li D, Wei Y, Dong Z, et al. Quantitative study on the early warning indexes of conventional sudden water pollution in a plain river network[J]. Journal of Cleaner Production, 2021, 303: 127067.
- [55] Fernández-Ortega J, et al. A common framework for the development of spring water contamination early warning system in western mediterranean karst areas: Spanish and french sites[J]. Science of The Total Environment, 2024, 956: 177294.
- [56] Wang Z, et al. Sustainable governance of drinking water conservation areas based on adaptive thresholds[J]. SSRN Electronic Journal, 2023.
- [57] Naim M, Bonaccorso B. Meteorological drought management in the mediterranean: Integrating satellite and reanalysis data for enhanced early warning systems in the tensift river basin[J]. SciForum Proceedings, 2024.
- [58] NASA. AppEEARS: Application for Extracting and Exploring Analysis Ready Samples [EB/OL]. National Aeronautics and Space Administration (NASA), 2023. <https://appeears.earthdatacloud.nasa.gov>.
- [59] 孔钦, 叶长青, 孙赞. 大数据下数据预处理方法研究[J]. 计算机技术与发展, 2018, 28(05): 1-4.
- [60] 刘明吉, 王秀峰, 黄亚楼. 数据挖掘中的数据预处理[J]. 计算机科学, 2000(04): 54-57.
- [61] Box G E P, Jenkins G M, Reinsel G C, et al. Time series analysis: Forecasting and control[M]. 5th ed. Hoboken: John Wiley & Sons, 2015.
- [62] 王凤英, 胡宝清. ARIMA 模型在时间序列分析中的应用研究[J]. 统计与决策, 2012(10): 153-155.
- [63] Savitzky A, Golay M J E. Smoothing and differentiation of data by simplified least squares procedures[J]. Analytical Chemistry, 1964, 36(8): 1627-1639.
- [64] Schafer R W. What is a savitzky-golay filter?[J]. IEEE Signal Processing Magazine, 2011, 28(4): 111-117.
- [65] Yu B, Yin H, Zhu Z. Spatio-temporal graph convolutional networks: A deep learning framework for traffic forecasting[C]//Proceedings of the 27th International Joint Conference on Artificial Intelligence (IJCAI). AAAI Press, 2018: 3634-3640.

- [66] Willmott C, Matsuura K. Advantages of the mean absolute error over the root mean square error in assessing model performance[J]. International Journal of Climatology, 2005, 25(5): 661-664.
- [67] Willmott C J, Matsuura K. Advantages of the mean absolute error over the root mean square error in assessing model performance[J]. International Journal of Climatology, 2005, 25(5): 661-664.
- [68] Jain A, Kumar A, Varshney A. Data normalization impact on artificial neural network for hydrological modeling[J]. Hydrological Sciences Journal, 2001, 46(3): 363-375.
- [69] Zhang Y, Li X, Wang L. Multi-task learning in water quality modeling: A case study in environmental monitoring[J]. Environmental Modelling & Software, 2021, 139: 104998.
- [70] Hinton G, Srivastava N, Krizhevsky A, et al. Improving neural networks by preventing co-adaptation of feature detectors[A]. 2012.